



UNIVERSIDAD ESAN  
FACULTAD DE INGENIERÍA  
INGENIERÍA DE TECNOLOGÍAS DE INFORMACIÓN Y SISTEMAS

**Aplicación de técnicas de Visión Computacional para la clasificación temprana de  
Rancha”Phytophthora infestans en las hojas de papa peruana**

Trabajo de investigación para el curso de Trabajo de Tesis I

Sebastian Puruguay  
Asesor: Marks Calderón

Lima, 3 de junio de 2024

# Índice general

|  |          |
|--|----------|
| <b>1. PLANTEAMIENTO DEL PROBLEMA</b>                   | <b>4</b> |
| 1.1. Descripción de la Realidad Problemática . . . . . | 4        |
| 1.2. Formulación del Problema . . . . .                | 7        |
| 1.2.1. Problema General . . . . .                      | 7        |
| 1.2.2. Problemas Específicos . . . . .                 | 7        |
| 1.3. Objetivos de la Investigación . . . . .           | 8        |
| 1.3.1. Objetivo General . . . . .                      | 8        |
| 1.3.2. Objetivos Específicos . . . . .                 | 8        |
| 1.4. Hipótesis . . . . .                               | 8        |
| 1.4.1. Hipótesis General . . . . .                     | 8        |
| 1.4.2. Hipótesis Específicas . . . . .                 | 8        |
| 1.5. Justificación de la Investigación . . . . .       | 9        |
| 1.5.1. Teórica . . . . .                               | 9        |
| 1.5.2. Práctica . . . . .                              | 10       |
| 1.5.3. Metodológica . . . . .                          | 10       |
| 1.6. Delimitación del Estudio . . . . .                | 10       |
| 1.6.1. Espacial . . . . .                              | 10       |
| 1.6.2. Temporal . . . . .                              | 11       |
| 1.6.3. Conceptual . . . . .                            | 11       |

|  |           |
|--|-----------|
| 1.6.4. Matriz de Consistencia . . . . .  | 11        |
| <b>2. MARCO TEÓRICO</b>  | <b>12</b> |
| 2.1. Antecedentes de la investigación . . . . .  | 12        |
| 2.1.1. Automated recognition of optical image based potato leaf blight diseases using deep learning ( <b>CHAKRABORTY2022101781</b> ) . . . . . | 12        |
| 2.1.2. Research and Validation of Potato Late Blight Detection Method Based on Deep Learning ( <b>antecedente2</b> ) . . . . .                 | 15        |
| 2.1.3. Supervised Learning-Based Image Classification for the Detection of Late Blight in Potato Crop ( <b>antecedente3</b> ) . . . . .        | 19        |
| 2.1.4. Potato Blight Classification Android Application using Deep Learning ( <b>antecedente5</b> ) . . . . .                                  | 22        |
| 2.1.5. Deep Convolutional Neural Networks for image based tomato leaf disease detection ( <b>antecedente6</b> ) . . . . .                      | 24        |
| 2.1.6. Potato Blight Classification Android Application using Deep Learning ( <b>antecedente7</b> ) . . . . .                                  | 26        |
| 2.1.7. Investigation of Phytophthora Infestans Causing Potato Late Blight Disease: A Review ( <b>antecedente4</b> ) . . . . .                  | 28        |
| 2.2. Bases Teóricas . . . . .  | 30        |
| 2.2.1. Inteligencia Artificial . . . . .   | 30        |
| 2.2.2. Deep Learning . . . . .   | 31        |
| 2.2.3. Vision Computer . . . . .   | 32        |
| 2.2.4. Vision Transformer: Explainability of Vision Transformers: A Comprehensive Review and New Perspectives ( <b>tecnica1</b> ) . . . . .    | 32        |
| 2.2.5. Redes neuronales convolucionales . . . . .  | 43        |
| 2.2.6. You Only Look One (YOLO) . . . . .  | 43        |
| 2.2.7. Support Vector Machine . . . . .  | 43        |
| 2.3. Marco Conceptual . . . . .  | 43        |

|  |           |
|--|-----------|
| <b>3. METODOLOGÍA DE LA INVESTIGACIÓN</b>                                  | <b>44</b> |
| 3.1. Diseño de la investigación . . . . .                                  | 44        |
| 3.1.1. Diseño no experimental . . . . .                                    | 44        |
| 3.1.2. Tipo explicativo . . . . .  | 44        |
| 3.1.3. Enfoque cuantitativo . . . . .                                      | 45        |
| 3.2. Población . . . . .   | 45        |
| 3.3. Muestra . . . . .   | 45        |
| 3.4. Operacionalización de Variables . . . . .                             | 45        |
| 3.5. Instrumentos de medida . . . . .                                      | 46        |
| 3.6. Técnicas de recolección de datos . . . . .                            | 47        |
| 3.7. Técnicas para el procesamiento y análisis de la información . . . . . | 47        |
| 3.8. Cronograma de actividades y presupuesto . . . . .                     | 48        |
| <b>A. Anexo I: Matriz de Consistencia</b>                                  | <b>49</b> |
| <b>B. Anexo II: Resumen de Papers investigados</b>                         | <b>51</b> |
| <b>C. Anexo III: Árbol del problema</b>                                    | <b>53</b> |
| <b>D. Anexo III: Árbol de objetivo</b>                                     | <b>54</b> |

# **Capítulo 1**

## **PLANTEAMIENTO DEL PROBLEMA**

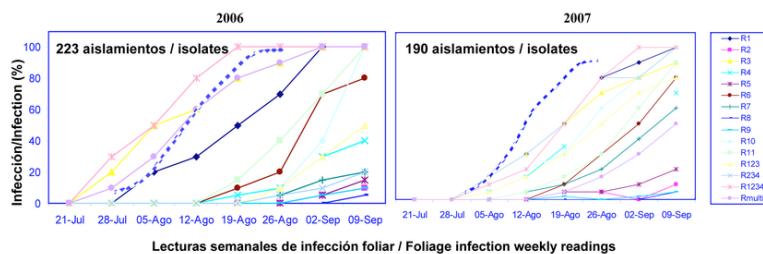
### **1.1. Descripción de la Realidad Problemática**

Hoy en día, la producción de papa es una de las actividades más importantes en nuestro país tanto a nivel económico como alimenticio y el Perú es el mayor productor de papa en América Latina contando con más de 4mil variedades.([cr'elcomercioproduccionpapa](#)).

De acuerdo al reporte del Ministerio de Desarrollo Agrario y Riego (Midagri) del 2023, el consumo de papa por persona es de, aproximadamente, 92 kilos por año, cifra que ha venido incrementándose desde hace dos décadas debido a la importancia que tiene este tubérculo en la dieta de los peruanos. La papa es considerada uno de los alimentos más importantes y nutritivos en el Perú, rico en carbohidratos, proteínas, vitaminas y minerales. Mientras que otros productos relevantes como el arroz no se cultivan en más de 7 regiones, lo que evidencia la amplia distribución geográfica del cultivo de papa en el territorio peruano ([cr'agroinforma1](#)). Asimismo, el tubérculo se siembra en 19 distintas regiones del país, resaltando en departamentos como Puno y Huánuco, que lideran la producción nacional con 20.6% y 12.6% respectivamente ([minagri'estadisticas'2022](#)). También, según el Censo Nacional Agropecuario 2022, el cultivo de papa es el sustento de al menos 710,000 familias en el Perú, representando aproximadamente el 25% de los hogares dedicados a la agricultura y aportando el 6.5% al PBI agropecuario del país ([inei'cenagro'2022](#)).

Sin embargo, en los últimos años, la producción se ha visto afectada por una de las patologías más mortales que es Phytophthora infestans, conocido por los agricultores como Rancha o tizón tardío, la cual es capaz de acabar con el 100% de cultivos enteros en solo unos días sino se antepone una medida de prevención. Según el técnico del Servicio para el Desarrollo Integral Rural, la rancha es peligrosa y puede arruinar toda la siembra. Es relevante

para el agricultor diagnosticarla y encontrar la mejor manera de controlarla. Las condiciones climáticas propicias para la aparición de la rancha o tizón tardío se dan cuando las temperaturas fluctúan entre los 15°C y 18°C, o bien, cuando la temperatura se mantiene por debajo de los 25°C durante un periodo de 7 días consecutivos. Asimismo, esta enfermedad se ve favorecida por la presencia de lluvias constantes o cuando los niveles de humedad relativa oscilan entre el 90 % y el 100% (**cr·rancha1**). Los principales síntomas de la enfermedad en el tubérculo son: hojas, lesiones en los bordes mostrando manchas necróticas con halo amarillento y micelio blanquecino en el relieve de la hojas; tallos, lesiones que recorren el tallo de color marrón osucro; tubérculos, lesiones irregulares en de color marrón rojizo que no solo están presentes en los alrededores de la papa sino del al interior también (**cr·rancha2**).



**Figura 1.1:** Lecturas semanales de infección foliar

Fuente: **cr·gestion2018emprend.** *El tizón tardío es capaz de llegar a un alto porcentaje de severidad en solo dos semanas.*

El caso más popular sobre rancha en Perú ocurrió en 2010 afectando a la región de Junín, donde al menos 26 mil de toneladas de papa fueron afectadas por la rancha en dos mil 660 hectáreas , lo cual representó una pérdida de 10 millones de nuevos soles. Esto se pudo evitar con fungicidas; sin embargo, estos son costosos entonces no todos los agricultores tiene acceso a este (**cr·rancha6**).

En abril de 2024, la rancha afectó a sembríos de papa nativa en la sierra de Lima, según reportes el tizón tardío arrasó con tres custodios de papa autóctonos tres en Huarachorí, dos en Yauyos y uno en Cajatambo (**cr·rancha3**). Asimismo, en marzo de 2024, la rancha afectó fuertemente en el departamento de Junín, haciendo que 2000 agricultores pierdan, aproximadamente, 550 hectáreas de papa por el tizón tardío, valorizando esta pérdida en S/300 mil. Siendo este el principal cultivo agrícola en su sierra (**cr·rancha4**). Finalmente, en abril de 2024, la rancha atacó el departamento de Apurímac, la cual perdió una hectárea de papa y una y media hectáreas de cultivos afectados (**cr·rancha5**).

Ante esto, el gobierno se ha visto obligado a concientizar sobre la rancha, en marzo de 2024, el Servicio para el Desarrollo Integral Rural (Sedir) y Servicio Nacional de Sanidad Agraria (Senasa) en Ancash, ya que varios agricultores locales temen perder sus sembríos de-

bido a la rancha, principalmente porque se desarrolla en temperaturas entre 12°C y 16°C y con fuerte presencia de humedad. Según la charla, una forma de prevenir la rancha es rotando el cultivo, es decir cambiando a otros productos como maíz y alverja (**cr'agroinforma2**).

Por eso mismo, con el gran avance de la Inteligencia Artificial (IA) se ha perfeccionado y popularizado su uso en el sector agrícola de distintas formas, ya que es una herramienta útil y apta para procesar enormes cantidades de información rápidamente. . La IA es una alternativa tecnología que puede brindar soluciones prácticas porque es eficiente creando algoritmos capaces de detectar patologías a tiempo, así como mejorar tanto la precisión del diagnóstico como la eficiencia del flujo de trabajo en el campo, además que reduce costes porque agiliza. La IA también se puede emplear para identificar a plantas que están en peligro de pescar una enfermedad específica, lo que facilita la intervención y prevención temprana. Por ejemplo, un estudio reciente mostró que un sistema de IA logró detectar la zona enferma de una hoja con una precision deñ 96.44 % (**cr'iaplanta**).

Añadiendo, la adopción de tecnología de IA en el ámbito de la agricultura del Perú puede ofrecer soluciones para una serie de problemas que enfrenta el sistema de siembra y cosecha, como el bajo acceso a asistencia técnica en este sector en el país, la escasez de personal, la falta de competencias y la insuficiencia de equipos tecnológicos para una mejor desempeño para el proceso agrícola. En muchas ocasiones, particularmente en las zonas rurales y de recursos limitados, la falta de tecnología agrícola adecuada puede restringir la productividad y la calidad de los cultivos en la agricultura peruana. Sin embargo, al emplear herramientas de inteligencia artificial, como sistemas de monitoreo automatizado de cultivos y análisis de datos agrícolas, se puede incrementar la eficiencia en la producción, reducir los costos y garantizar una mayor calidad de los productos agrícolas, beneficiando así a más agricultores y contribuyendo al desarrollo sostenible del sector. En muchos casos, especialmente en las áreas rurales y de bajos ingresos del Perú, la falta de equipamiento agrícola básico y adecuado limita el rendimiento y la productividad de los cultivos. Al utilizar herramientas de inteligencia artificial, como sistemas de monitoreo de cultivos, análisis de patologías en cultivos y predicción del clima, se puede mejorar la toma de decisiones en cuanto a la siembra, el riego y la aplicación de insumos, optimizando los recursos y aumentando los rendimientos, lo que permite una mayor producción agrícola para alimentar a más personas. Un porcentaje significativo de los trabajos se enfocan en la detección y diagnóstico de enfermedades (29.4 %) y en la recomendación de fertilizantes (29.4 %), sin embargo, este último aspecto no abarca específicamente el cultivo de maíz. Los sistemas expertos están diseñados principalmente para que el agricultor pueda tomar decisiones más acertadas durante el ciclo de cultivo, lo cual representa el 80.6 % de los casos. Estos sistemas se consideran usuarios potenciales, ya que muchos agricultores no tienen los recursos para contratar a un experto en el área. Los sistemas expertos ofrecen una alternativa

accesible y de bajo costo (**criaplanta2**).

En este sentido, la presente investigación busca desarrollar e implementar un sistema robusto y escalable de visión computacional, aprovechando los avances tecnológicos más recientes, con el fin de proporcionar una solución innovadora, accesible y de alto impacto para los agricultores peruanos, facilitando la lucha contra esta devastadora enfermedad y promoviendo la resiliencia y productividad de los cultivos de papa a nivel nacional.

## 1.2. Formulación del Problema

Para la formulación de los problemas de la presente investigación, se elaboró un «árbol de problemas» (véase Anexo [C.1](#)).

### 1.2.1. Problema General

¿Es posible desarrollar un sistema de visión computacional que permita la clasificación temprana de la rancha (*Phytophthora infestans*) en hojas de papa peruana con alta precisión?

### 1.2.2. Problemas Específicos

- ¿Cómo podemos desarrollar un sistema de detección automática de Rancha”*Phytophthora infestans* en las hojas de papa peruana que sea preciso, eficiente y robusto a la variabilidad de las lesiones y las condiciones ambientales?
- ¿Cómo obtener un conjunto de datos representativo y diverso de imágenes de hojas de papa con Rancha y sin ella?
- ¿Cuáles son las técnicas de visión computacional más apropiadas para la detección temprana de Rancha.<sup>en</sup> hojas de papa peruano?
- ¿Cuáles son las técnicas de preprocessamiento de imágenes más apropiadas para la detección temprana de Rancha.<sup>en</sup> hojas de papa peruano??

## 1.3. Objetivos de la Investigación

### 1.3.1. Objetivo General

Desarrollar un sistema de visión computacional basado en técnicas de aprendizaje profundo para la clasificación temprana de la rancha (*Phytophthora infestans*) en hojas de papa peruana.

### 1.3.2. Objetivos Específicos

- Desarrollar un sistema de detección automática de Rancha”*Phytophthora infestans* que alcance una precisión alta en la detección de lesiones en las hojas de papa.
- Recolectar un conjunto de datos amplio y diverso de imágenes de hojas de papa que cubra una variedad de condiciones y escenarios relevantes para la detección de la Rancha.
- Identificar las técnicas de visión computacional más adecuadas para la detección temprana de Rancha.<sup>en</sup> hojas de papa peruana.
- Identificar las técnicas de procesamiento de imágenes más adecuadas para la detección temprana de Rancha.<sup>en</sup> hojas de papa peruana.

## 1.4. Hipótesis

### 1.4.1. Hipótesis General

Se sostiene que mediante el desarrollo de un sistema de clasificación automática de las lesiones de Rancha”*Phytophthora infestans* en las hojas de papa peruana, se puede lograr un método de detección la Rancha en las hojas de papa peruana.

### 1.4.2. Hipótesis Específicas

- HE1: La implementación de técnicas de aprendizaje automático y detección de imágenes permitirá desarrollar un sistema de detección automática de Rancha”*Phytophthora infestans* con alta precisión.

- HE2: La recopilación de un conjunto de datos representativo y diverso proporcionará una base sólida para el entrenamiento y la validación de los algoritmos de visión computacional, lo que mejorará su capacidad para detectar con precisión la Rancha en las hojas de papa.
- HE3: Se sostiene que al investigar específicamente técnicas de visión computacional, se logrará una mejora significativa en la detección temprana de Rancha.<sup>en</sup> hojas de papa peruano.
- HE4: Se sostiene que al investigar específicamente técnicas de preprocessamiento de imágenes, se logrará una mejora significativa en la detección temprana de Rancha.<sup>en</sup> hojas de papa peruano.

Los problemas, objetivos e hipótesis descritas anteriormente se encuentran alineados en la Matriz de Consistencia del Anexo A.1. Además, los objetivos específicos se formularon a partir de una lluvia de ideas luego de examinar los objetivos planteados en los antecedentes, cuyo detalle e ítem de referencia se encuentra en el Anexo D.1.

## 1.5. Justificación de la Investigación

### 1.5.1. Teórica

El propósito de esta investigación es contribuir al avance en la clasificación temprana de la 'Rancha' Phytophthora infestans en las hojas de papa peruana mediante la aplicación de técnicas de Visión Computacional. Este problema reviste importancia debido a su impacto en la agricultura peruana, donde la detección temprana de la enfermedad es crucial para su manejo efectivo.

Cabe recalcar que cada vez este tipo de herramientas tecnológicas son más útiles para la clasificación de patologías visuales en las hojas de plantas. Asimismo, es importante resaltar que no hay este tipo de investigaciones en Perú, siendo uno de los países con más historia con la papa y que cuenta con miles de variedades.

Al implementar este enfoque multimodal, se espera proporcionar una herramienta útil para los agricultores y expertos en la detección temprana de la 'Rancha' Phytophthora infestans, lo que eventualmente podría contribuir a una mejor gestión de esta enfermedad y a la protección de los cultivos de papa en el Perú.

### 1.5.2. Práctica

Muchos de los trabajos previos, superaron su efectividad y precision esperada; sin embargo, en gran mayoría de la literatura mencionada (5 de 5) utilizaron técnicas comunes y antiguas, ninguno optó por utilizar técnicas innovadoras como Visual Transformer que en este caso sí se dará.

Al concluir esta investigación, las personas podrán hacer uso del sistema de clasificación temprana de la 'Rancha' Phytophthora infestans en las hojas de papa peruana con el fin de tomar las medidas apropiadas para su control y erradicación. De encontrarse, con una plantación infectada deberán utilizar pesticidas especializados para esos casos de manera profesional. Los beneficiados serán aquellas personas que viven de la cultivación de este tubérculo, tales como agricultores, campesinos, negociantes y el consumidor final. Esta investigación va a servir para evitar un tardía reacción a la Rancha en los cultivos de papa para que así no haya pérdida de cosecha. El trabajo presente demostrará que un sistema de vision computacional puede clasificar, mediante imágenes RGB de hojas de planta de papa, si el tubérculo presenta la enfermedad de tizón tardío, lo cual puede cambiar el proceso de cuidado de cultivo y no solo del agricultor sino de toda la caneda que se beneficia de este producto.

### 1.5.3. Metodológica

La implementación del modelo propuesto ayudará a agricultores a clasificar tempranamente el tizón tardío en la papa haciendo su trabajo más rápido y eficiente, ya que una detección temprana promete ser una rápida toma de decisiones que ayudará solucionar y controlar este problema.

Para ello, se utilizaron técnicas Vision Computacional entrenados con un conjunto de datos compuesto por distintas bases de datos reales luego de un proceso de recolección de datos.

## 1.6. Delimitación del Estudio

### 1.6.1. Espacial

Para la presente investigación, se consideraron proyectos de tecnología de distintas ciudades y países, mayoritariamente del territorio de latonamericano. Sin embargo, la información textual (descripción y comentarios) para la fase de entrenamiento solo se tomó en cuenta palabras en inglés.

### **1.6.2. Temporal**

El periodo de tiempo abarcará desde el año 2019, fecha en el cual se tiene registrado los primeros conjuntos de datos de proyectos en Kickstarter hasta el mes de agosto del año 2024, últimos registros descargados hasta el inicio del presente trabajo. Asimismo, obtener nuevos algoritmos y resultados que validen que las mismas técnicas pueden ser aplicadas en diferentes contextos.

### **1.6.3. Conceptual**

Esta investigación se orientará en la implementación de un modelo que logre clasificar si una o varias hojas de papa están infectadas con ranchera. Para ello, se valió del uso de herramientas de Vision computacional para desarrollar los modelos de acuerdo a sus modalidades respectivas.

### **1.6.4. Matriz de Consistencia**

A continuación se presenta la matriz de consistencia elaborada para la presente investigación (véase Anexo A.1).

# **Capítulo 2**

## **MARCO TEÓRICO**

### **2.1. Antecedentes de la investigación**

En esta sección se mostrarán diferentes artículos de investigación y tesis que tratan sobre diversas técnicas y enfoques utilizados para enfrentar problemas similares a los abordados en esta tesis. Además, se incluye un cuadro resumen (véase Anexo B.1) con la información presentada en esta sección.

#### **2.1.1. Automated recognition of optical image based potato leaf blight diseases using deep learning (CHAKRABORTY2022101781)**

**CHAKRABORTY2022101781** realizó un artículo de investigación el cual fue publicado en la revista «Physiological and Molecular Plant Pathology» en el año 2022. Este fue titulado **CHAKRABORTY2022101781** la cual traducida al español significa «Reconocimiento automatizado de enfermedades del tizón de la hoja de la papa basado en imágenes ópticas mediante aprendizaje profundo». La investigación sostiene que el Tizón tardío se presenta como manchas en las hojas de la papa y que para su detección los agricultores sospechan de la patología lo que arriesga los cultivos debido a esta subjetividad y enorme consumo de tiempo. Asimismo, el trabajo explora diferentes recientes modelos de Deep Learning, los cuales los compara con técnicas existentes.

### **2.1.1.1. Planteamiento del Problema y objetivo**

El artículo aborda la papa como uno de los alimentos más consumidos a nivel mundial, el cual es un elemento relante en la dieta dieria de 1.5 mil millones de personas, pero que se ve afectado por varias patologías. Se plantea que una de las temidas es el Tizón tardío, la cual afecta el rendimiento de producción del tubérculo. Por eso, se requiere una detección temprana para implementar las estrategias de maneja eficaces. Sin embargo, las prácticas convencionales para su diagnóstico, como la inspección visual, son subjetivos y demandan enorme cantidad de tiempo. Por lo tanto, el artículo plantea que se necesita modelos computacionales avanzados para su clasificación temprana de estas enfermedades, para implementar una gestión y el control de las mismas en la papa. Los principales objetivos son explorar y entrenar modelos de aprendizaje profundo, identificar el modelo de mejor desempeño, optimizar el modelo seleccionado, comparar el modelo propuesto con técnicas existentes y proveer una solución práctica y eficiente.

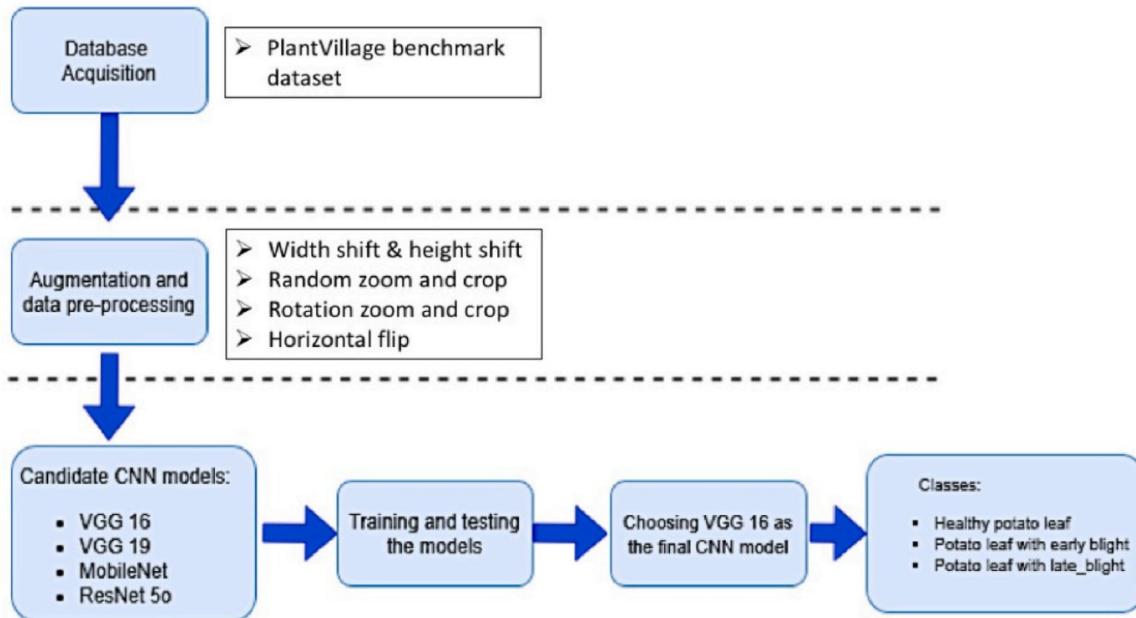
### **2.1.1.2. Fundamento Teórico usado por el Autor**

El autor planteó emplear recientes modelos de Deep Learning, los principales modelos que utilizó fueron VGG16, VGG19, ResNet50 y MobileNet utilizando imágenes ópticas de hojas de papa del conjunto de datos PlantVillage.

### **2.1.1.3. Metodología empleada por los autores**

La metodología empleada por el autor, para la creación de su chatbot consiste en 6 pasos:

1. Se adquirió la base de datos de imágenes del conjunto de datos PlantVillage, del cual solo extrajo imágenes de hoja de papa.
2. Realizaron un preprocesamiento de imágenes donde usaron las técnicas de Cambio de ancho, Cambio de Largo, Zoom y recorte aleatorios, Zoom y recortes rotativos y Giro horizontal
3. Los CNN candidatos fueron VGG16, VGG19, ResNet50 y MobileNet
4. Entrenamiento y testeо de los modelos.
5. Se eligió VGG16 como modelo final

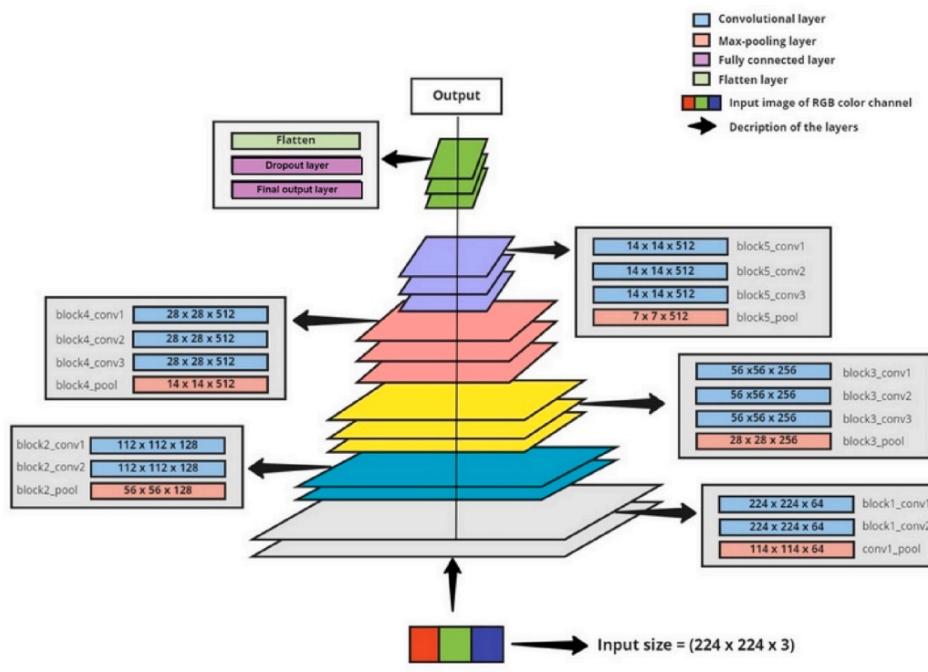


**Figura 2.1:** Metodología propuesta para el modelo (**CHAKRABORTY2022101781**)

6. Las clases que el modelo clasificaba son, Hoja de papa sana, Hoja de papa con Tizon temprano, Hoja de papa con Tizon tardío

#### 2.1.1.4. Resultados obtenidos

En el paper, cuando se evalúan las distintas técnicas de CNN a considerar, la que sobresale y tiene un mayor desempeño logrando un accuracy promedio del 92.69 %. Es por eso, que se tunea y se escoge como la técnica principal para el desarrollo del modelo final, obteniendo un accuracy promedio del 97.89 %.



**Figura 2.2:** Arquitectura del modelo ajustado propuesto de VGG16, muestra las disntitas capas (convolucion). Tambien, se mencionana los respectivos tamaños del filtro convolucional (**CHAKRABORTY2022101781**)

### 2.1.2. Research and Validation of Potato Late Blight Detection Method Based on Deep Learning (antecedente2)

**antecedente2** realizó este trabajo publicado en la revista Agronomy, para la sección de Precision and Digital Agriculture. Este fue titulado **antecedente2** la cual traducida al español significa «Investigación y validación del método de detección del tizón tardío de la papa basado en aprendizaje profundo». La investigación nos dice que el Tizón tardío puede llevar al fracaso total del cultivo papa. Asimismo, construyeron un total de siete categorías de conjuntos de datos de enfermedades de las hojas de papa en fondos simples y complejos. Finalmente, la investigación se introduce en diferentes modelos de Deep Learning en distintas versiones.

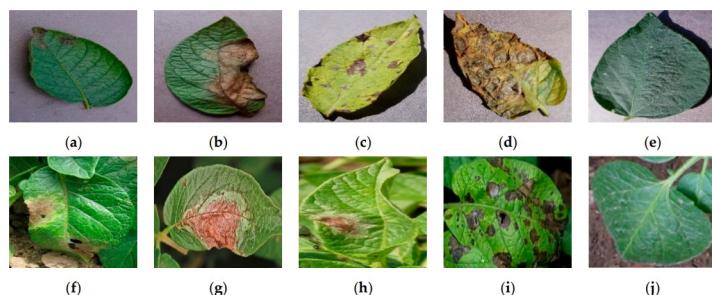
#### 2.1.2.1. Planteamiento del Problema y objetivo

El trabajo discute sobre el Tizón tardío como enfermedad muy grave para los cultivos de papa. Esta pone en riesgo el total del cultivo, además que los métodos tradicionales como la detección basada en la inspección visual suele ser subjetivo y demora tiempo. Asimismo, los sistemas de detección actuales suelen ser ineficientes debido a la variabilidad de luminosidad

y el sombreado de las hojas. Es crucial desarrollar un modelo de detección automatizada que pueda superar estas limitaciones, permitiendo una monitorización y prevención temprana del tizón tardío de la papa. El objetivo de este estudio es desarrollar y optimizar un modelo de aprendizaje profundo para la detección del tizón tardío en hojas de papa, que sea altamente preciso y rápido en su inferencia, y que pueda ser implementado en dispositivos móviles para la monitorización automática y la alerta temprana de enfermedades en cultivos. Para alcanzar este objetivo, se plantean las siguientes metas específicas: Lograr una clasificación detallada de enfermedades, Optimizar el modelo base elegido, Evaluar la viabilidad y efectividad del modelo en hardware.

### 2.1.2.2. Fundamento Teórico usado por el Autor

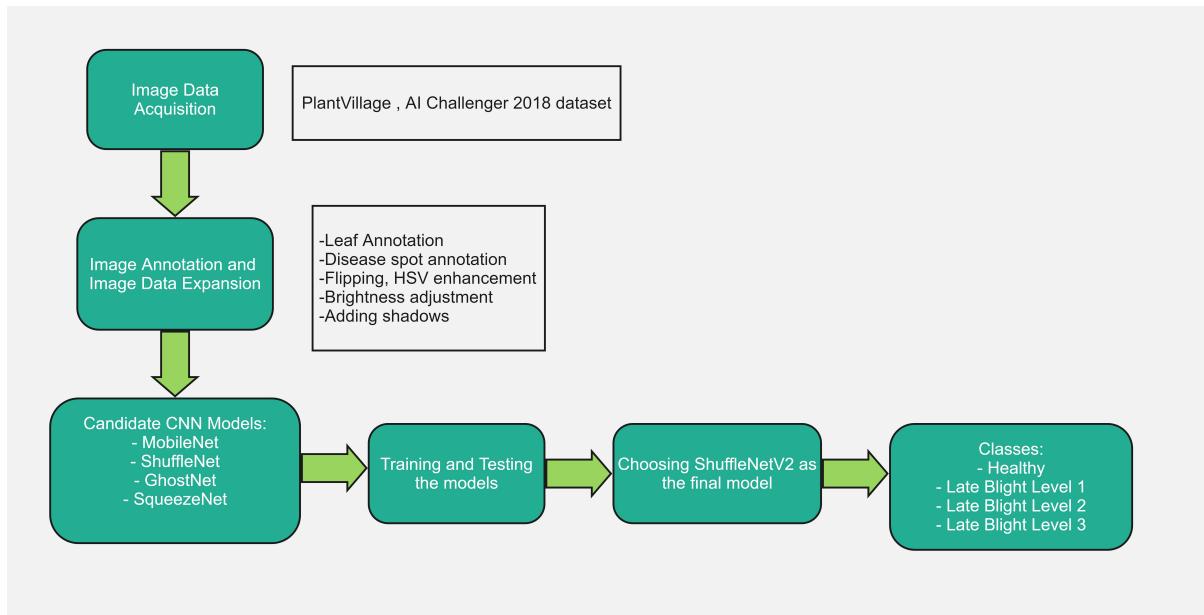
El autor planteó utilizar modelos de Deep Learning, se enfocó en modelos de ligeros y eficientes estos con el fin de implantar el modelo en un dispositivo móvil. Las técnicas que utilizó fueron MobileNet, ShuffleNet, GhostNet, and SqueezeNet pre-trained models usando imágenes de hojas de papa de los conjuntos de dato Plant Village y AI Challenger 2018.



**Figura 2.3:** (a) Etapas tempranas de la hoja con tizón tardío en un contexto único. (b) Etapas finales de la hoja con tizón tardío en un contexto único. (c) Etapas tempranas de la hoja con tizón temprano en un contexto único. (d) Etapas finales de la hoja con tizón temprano en un contexto único. (e) Hoja sana en un contexto único. (f) Etapas tempranas de la hoja con tizón tardío en un contexto natural. (g) Etapas finales de la hoja con tizón tardío en un contexto natural. (h) Etapas tempranas de la hoja con tizón temprano en un contexto natural. (i) Etapas finales de la hoja con tizón temprano en un contexto natural. (j) Hoja sana en un contexto natural. (**antecedente2**)

### 2.1.2.3. Metodología empleada por los autores

La metodología empleada por el autor, para la creación de su modelo final de clasificación es el siguiente:

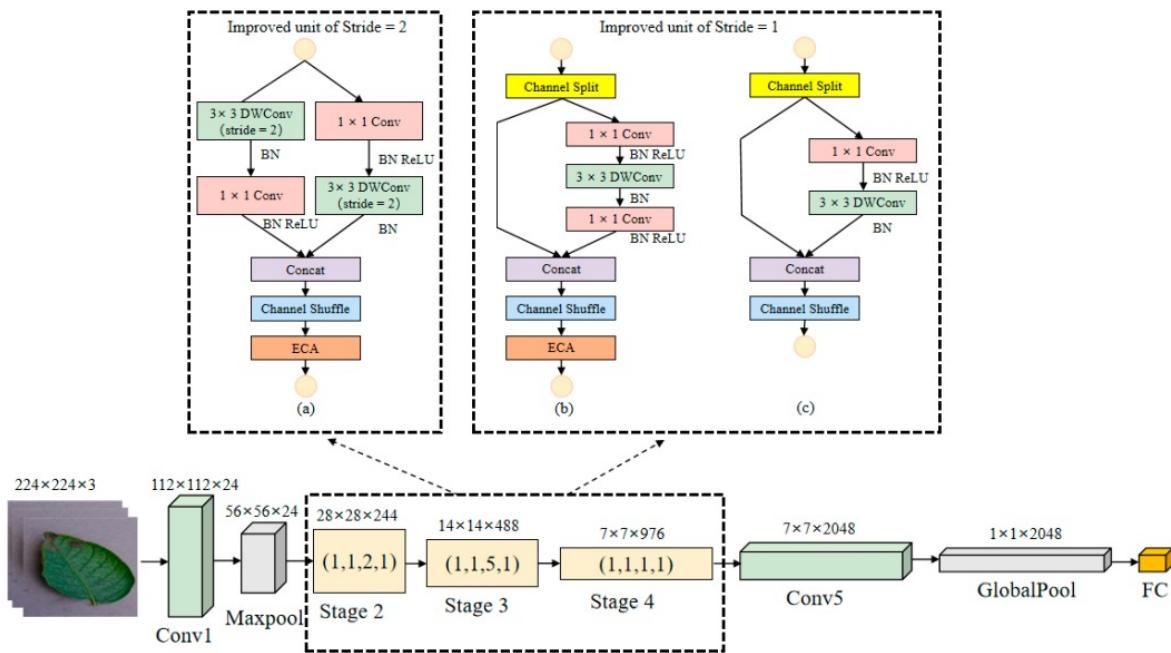


**Figura 2.4:** Arquitectura del bot de Azure (**antecedente2**)

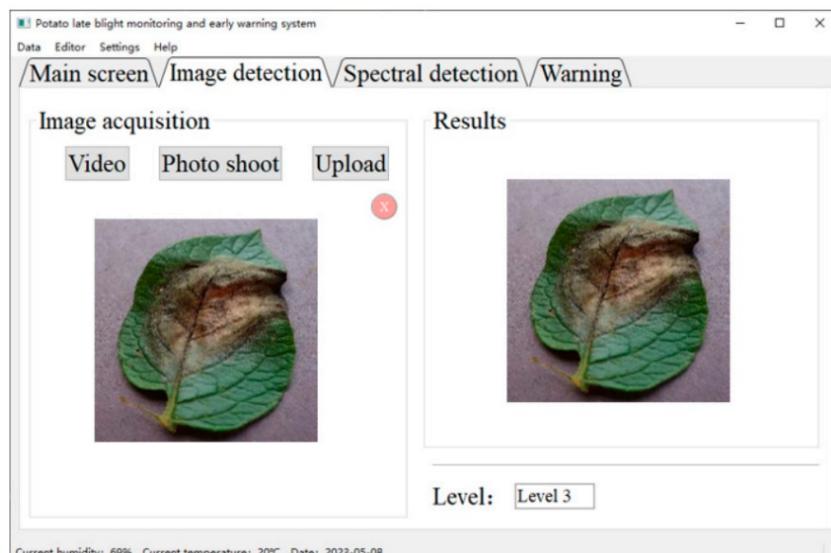
1. Se adquirió la base de datos de imágenes del conjunto de datos PlantVillage y IA Challenger 2018 dataset, del cual solo extrajo imágenes de hoja de papa.
2. Realizaron un preprocesamiento de imágenes donde usaron técnicas para la Anotación de hoja, Zona de enfermedad, Volteo de imagen, Mejora HSV, Ajuste de brillo, Agregar sombras
3. Los CNN candidatos fueron MobileNet, ShuffleNet, GhostNet y SqueezeNet
4. Entrenamiento y testeо de los modelos.
5. Se eligió ShuffleNetV2 como modelo final
6. Las clases que el modelo clasificaba son, Hoja de papa sana, Tizón tardío nivel 1, Tizón tardío nivel 2 y Tizón tardío nivel 3

#### 2.1.2.4. Resultados obtenidos

En esta investigación, se analizaron distintos resultados con diferentes técnicas. Con la técnica final, ShuffleNetV2, se obtuvieron resultados un accuracy de 95.41 %. Finalmente, se consideró una mejoría para esta técnica, ya que se buscaba el mejor modelo final posible para un dispositivo móvil disminuyendo el tiempo de procesamiento y el costo computacional, tomando esos objetivos en cuenta, se logró un 95.04 %



**Figura 2.5:** Arquitectura del modelo final. La estructura del modelo mejorado ShuffleNetV2 2x. Nota: La Etapa 2, la Etapa 3 y la Etapa 4 están compuestas por la unidad base original, con Stride = 1, y la unidad modificada está compuesta por una unidad con Stride = 1 y una unidad con Stride = 2. (1, 1, 2, 1) en la Etapa 2 indica una pila de la unidad (a) con Stride = 2 mejorado, una pila de la unidad (b) con Stride = 1 mejorado, dos pilas de la unidad básica con Stride = 1 original, y una pila de la unidad (c) con Stride = 1 mejorado; (1, 1, 5, 1) en la Etapa 3 indica una pila de la unidad (a) con Stride = 2 mejorado, una pila de la unidad (b) con Stride = 1 mejorado, cinco pilas de la unidad básica con Stride = 1 original, y una pila de la unidad (c) con Stride = 1 mejorado; (1, 1, 1, 1) en la Etapa 4 indica una pila de la unidad (a) con Stride = 2 mejorado, una pila de la unidad básica con Stride = 1 original, y una pila de la unidad (c) con Stride = 1 mejorado. ([antecedente2](#))



**Figura 2.6:** Interfaz de operación de detección de imágenes. ([antecedente2](#))

### **2.1.3. Supervised Learning-Based Image Classification for the Detection of Late Blight in Potato Crop (antecedente3)**

**antecedente3** realizó un trabajo con el fin de ser publicado en la revista Computer Vision and Pattern Recognition Based on Deep Learning. Este fue titulado **antecedente3** la cual traducida al español significa «Clasificación de imágenes basada en aprendizaje supervisado para la detección del tizón tardío en cultivos de papa». La investigación plantea el desarrollo de un modelo de detección temprana del Tizón tardío en la papa utilizando Redes Neuronales Convolucionales y Máquinas de Vectores de Soporte. Asimismo, el autor desarrolló, por sí mismo, su base de datos de imágenes de cultivos de papa. Finalmente, se aplicaron varias métricas de rendimiento, eficiencia y calidad en las tareas de aprendizaje y clasificación para determinar los mejores algoritmos de aprendizaje automático.

#### **2.1.3.1. Planteamiento del Problema y objetivo**

La investigación aborda la necesidad de encontrar métodos más eficaces en cuanto a la detección temprana del Tizón Tardío causada por Oomiceto Phytophthora, que afecta rápidamente las hojas, tallos y tubérculos de la papa que es un alimento crucial en la economía de Bógora. Asimismo, la detección tradicional, como pruebas de laboratorio, aunque es eficaz, toma mucho tiempo y es altamente costoso. En conclusión, el objetivo principal del estudio es aplicar técnicas de aprendizaje supervisado y clasificación de imágenes, específicamente mediante redes neuronales convolucionales (CNN) y máquinas de vectores de soporte (SVM), para la detección temprana del tizón tardío en cultivos de papa.

#### **2.1.3.2. Fundamento Teórico usado por el Autor**

El autor plantea hacer uso de CNN y SVM como sus posibles modelos finales. Utiliza una CNN, según el preprocessamiento de la data, no modificada y una aumentada, por otro lado, divide SVM en cuatro posibles modelos según característica del preprocessamiento: Color, Textura, PCA, Combined.

#### **2.1.3.3. Metodología empleada por los autores**

La metodología empleada por el autor, para la creación de su modelo consiste en los siguientes pasos:

1. Captura los datos imputados por parte del cliente.

2. Envía el query a Dialogflow para su procesamiento.
3. Se procesa la información mediante una API externa y el código implementado, así como la base de datos.
4. Retorna los resultados procesados y se agrega información extra requerida.
5. Envía al cliente o usuario la respuesta.

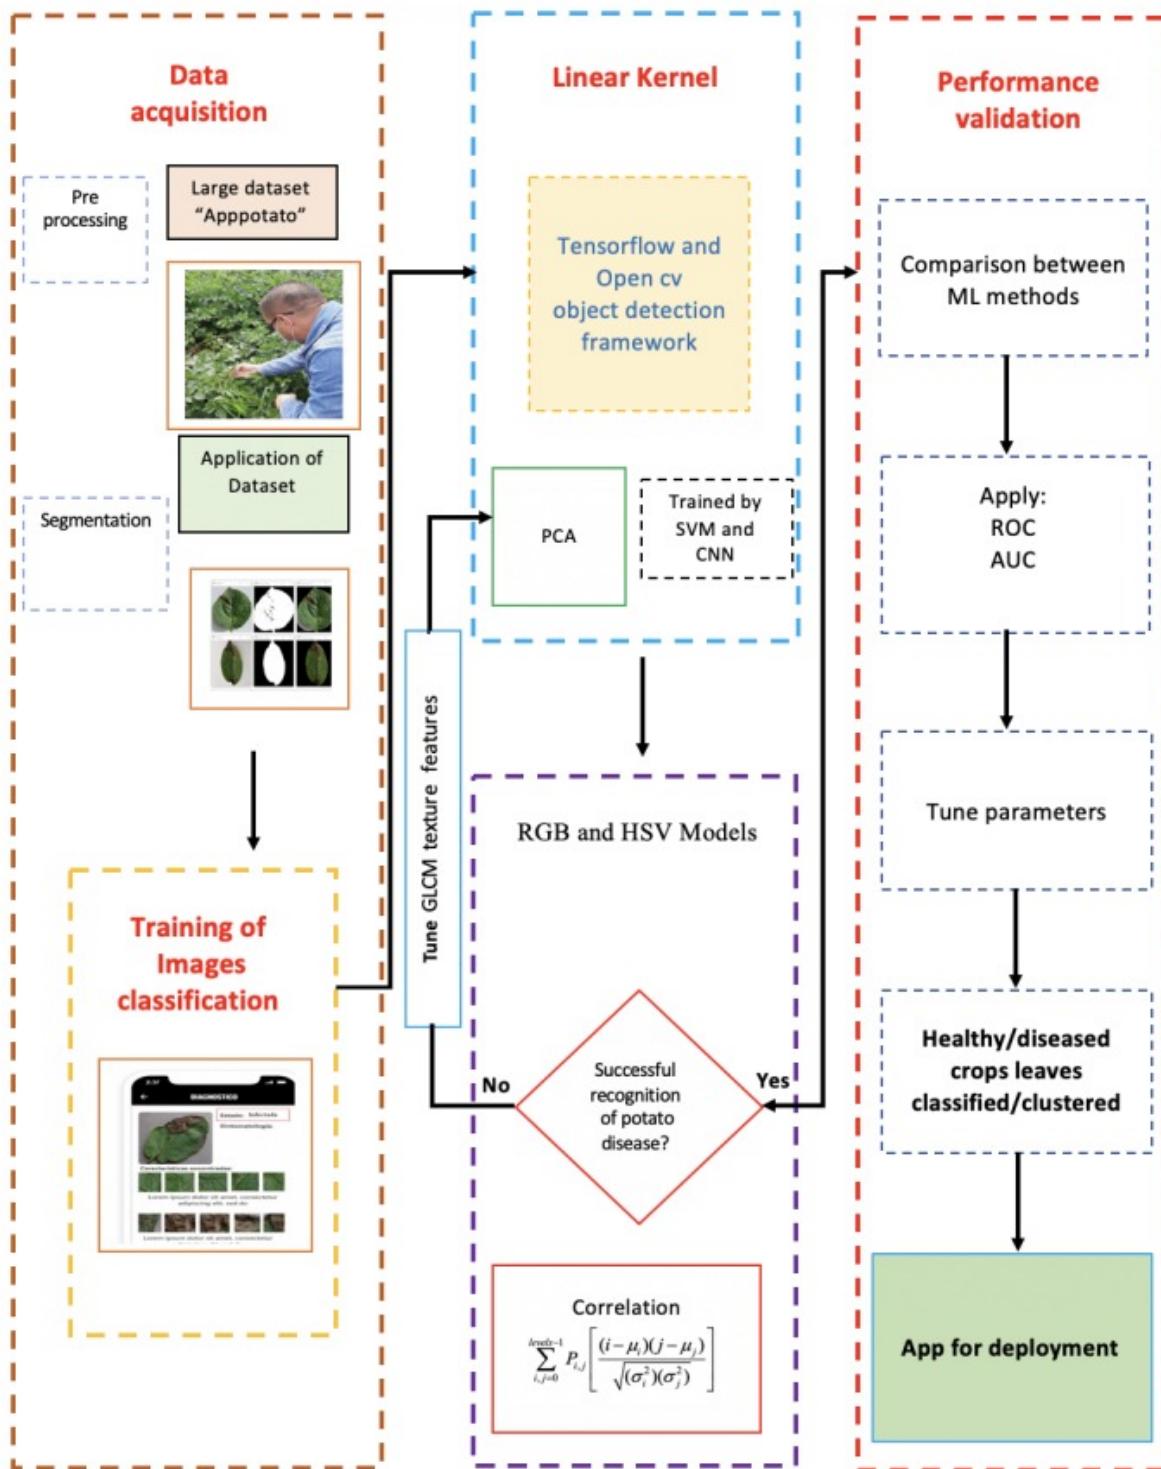


Figura 2.7: Diagrama de la metodología Flowchart(**antecedente3**)

#### **2.1.3.4. Resultados obtenidos**

Las CNN entrenadas con el conjunto de datos aumentado mostraron el mejor desempeño con una precisión del 93 % y una AUC de 0.97. Además, las SVM entrenadas con características de color obtuvieron mejores resultados en comparación con las SVM entrenadas con otras características. Finalmente, se propone desarrollar una aplicación móvil con características avanzadas para la agricultura de precisión que ayude a los agricultores a identificar la enfermedad del tizón tardío de manera no invasiva y en tiempo real..

#### **2.1.4. Potato Blight Classification Android Application using Deep Learning (antecedente5)**

**antecedente5** realizó un artículo publicado en base de datos de ELSEVIER, siendo también parte de la revista Sustainable Chemistry and Pharmacy en el año 2022. Este fue titulado **antecedente5** la cual traducida al español significa «Redes neuronales convolucionales profundas para la detección de enfermedades de la hoja del tomate basada en imágenes». El trabajo nos dice que el reconocimiento de enfermedades foliares en las plantas representa un riesgo significativo para la seguridad alimentaria, ya que puede reducir la producción agrícola y, por ende, la economía nacional. Es crucial identificar estas enfermedades en etapas tempranas para mejorar la calidad y cantidad de los productos agrícolas. Por lo tanto, se requiere un sistema automático de reconocimiento de enfermedades foliares que pueda identificar y clasificar estas enfermedades en etapas tempranas. En este contexto, se han utilizado modelos de redes neuronales convolucionales profundas (DCNN) para el análisis de imágenes de hojas, con el objetivo de mejorar la precisión y reducir el tiempo de respuesta en la identificación de enfermedades foliares en tomates. Se propone un sistema automático de identificación de enfermedades foliares en tomates utilizando DCNN, con un conjunto de datos de 18160 imágenes de hojas de tomate. Este conjunto de datos se dividió en un 60 % para entrenamiento y un 40 % para pruebas, logrando una precisión del 98.40 % en el conjunto de pruebas con el modelo DCNN propuesto.

##### **2.1.4.1. Planteamiento del Problema y objetivo**

El artículo aborda principalmente que las enfermedades en las hojas de tomate causan pérdidas significativas en la producción, afectando tanto la calidad como la cantidad de los productos. Identificar y diagnosticar estas enfermedades de manera temprana es crucial, ya que pueden reducir drásticamente el crecimiento de los cultivos y, por lo tanto, la producción. Sin

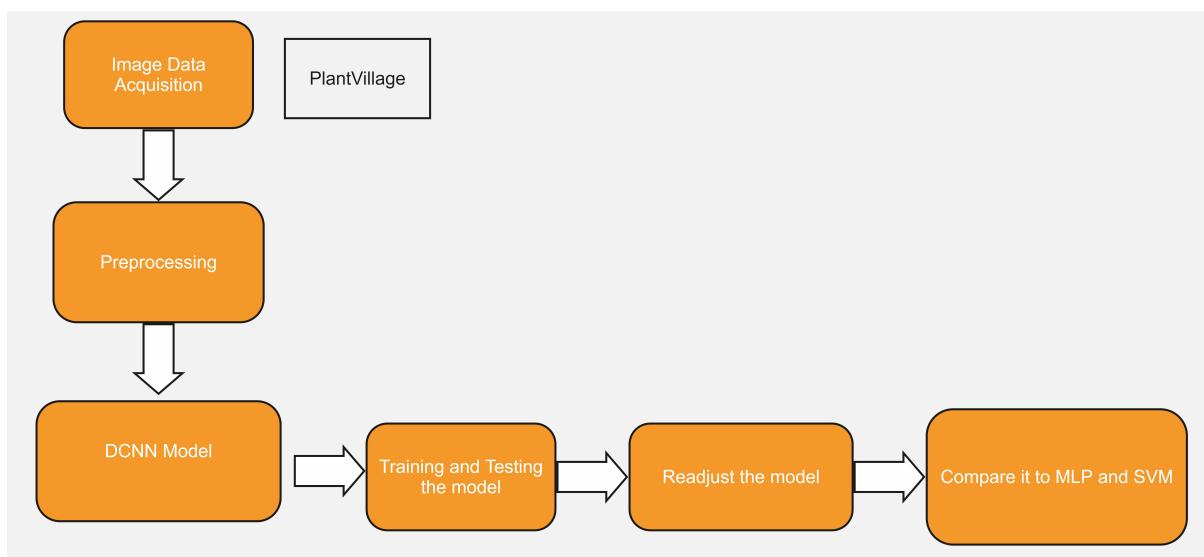
embargo, el diagnóstico manual de las enfermedades foliares puede llevar a una disminución en la producción debido a la gravedad de las enfermedades y a la variabilidad en los síntomas causada por factores ambientales como la temperatura, el viento y la humedad. Por lo tanto, existe una necesidad de desarrollar un sistema automático que pueda identificar y diagnosticar estas enfermedades en etapas tempranas, permitiendo a los agricultores tomar medidas preventivas adecuadas para proteger sus cultivos. El objetivo es desarrollar una herramienta automática que diagnostique las enfermedades de las hojas de tomate tempranamente para mejorar la producción agrícola. Se utilizará un enfoque basado en redes neuronales convolucionales profundas (DCNN) para clasificar 10 tipos de enfermedades en los cultivos de tomate, con el fin de identificar los síntomas de las hojas en etapas tempranas y mejorar la eficiencia y precisión del modelo mediante técnicas de ajuste de parámetros.

#### 2.1.4.2. Fundamento Teórico usado por el Autor

Los autores plantean utilizar como técnica principal una DCNN (Deep Convolutional Neural Networks) y compararla con técnicas como MLP (Multiplayer Layer Perceptron) y SVM (Support Vector Machine).

#### 2.1.4.3. Metodología empleada por los autores

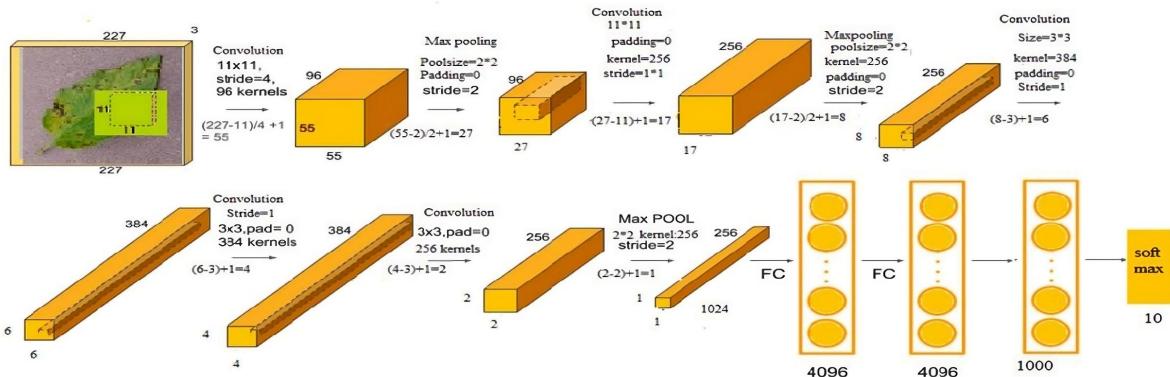
La metodología empleada por los autores, para la creación de su chatbot consiste en los siguientes pasos:



**Figura 2.8: Metodología (antecedente5)**

#### 2.1.4.4. Resultados obtenidos

Como resultado del desarrollo del modelo final, este alcanzó un 98.40 % de accuracy promedio, mientras que SVM obtuvo un accuracy de 90.01 % y MLP un accuracy de 88.30 %.



**Figura 2.9:** Arquitectura del modelo final (**antecedente5**)

#### 2.1.5. Deep Convolutional Neural Networks for image based tomato leaf disease detection (**antecedente6**)

**antecedente6** realizó un artículo publicado en base de datos de International Journal of Advanced Research in Science, Communication and Technology (IJARSCT) en el año 2023. Este fue titulado **antecedente6** la cual traducida al español significa «Aplicación para Android de clasificación del tizón de la papa usando el aprendizaje profundo». La investigación sostiene que los agricultores de papas sufren pérdidas económicas debido a enfermedades como el tizón temprano y tardío. La detección temprana y tratamiento adecuado pueden prevenir estas pérdidas, pero los métodos tradicionales son lentos y propensos a errores. Proponemos usar una Red Neuronal Convolucional (CNN) personalizada para diagnosticar enfermedades de plantas de manera rápida y precisa, reduciendo el tiempo de computación y minimizando errores, lo que ayuda a los agricultores a tratar las enfermedades a tiempo y reducir pérdidas.

##### 2.1.5.1. Planteamiento del Problema y objetivo

El trabajo sustenta que la industria de la papa enfrenta un desafío significativo en la prevención de pérdidas de cultivos debido a enfermedades como el tizón temprano y el tizón tardío. Estas enfermedades pueden causar pérdidas económicas sustanciales para los agricultores si no se detectan y tratan a tiempo. Los métodos tradicionales de inspección visual son

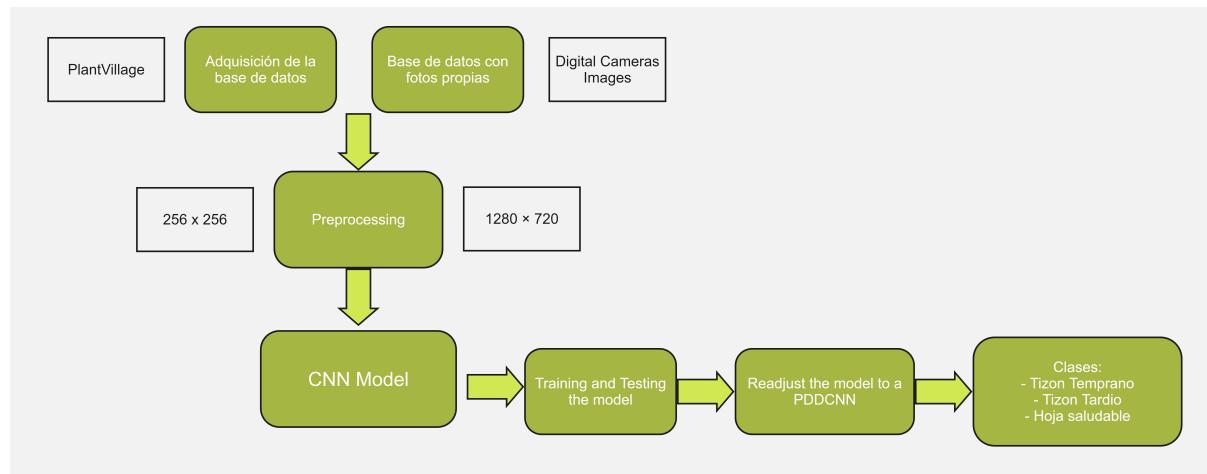
lentos, propensos a errores y no son viables para aplicaciones en tiempo real debido a los largos tiempos de procesamiento de imágenes. Además, existe la necesidad de mejorar la precisión y reducir el tiempo de computación en los métodos actuales de diagnóstico de enfermedades de las plantas. Por eso, su objetivo es desarrollar una red neuronal convolucional (CNN) eficiente y precisa para detectar enfermedades en las plantas de papa, reduciendo el tiempo de computación y mejorando la precisión, con el fin de ayudar a los agricultores a tratar las enfermedades a tiempo y reducir pérdidas económicas.

### 2.1.5.2. Fundamento Teórico usado por el Autor

Los autores formulan utilizar como técnica principal un Red Neuronal Convolutual, mejorarla para que sea una Red neuronal convolucional personalizada de enfermedades profundas (PDDCNN), ya que buscan lograr un modelo que se adapte a distintas regiones de donde se pueda obtener el dataset.

### 2.1.5.3. Metodología empleada por los autores

La metodología empleada por los autores, para la creación de su chatbot consiste en los siguientes pasos:



**Figura 2.10:** Metodología (antecedente6)

### 2.1.5.4. Resultados obtenidos

Los resultados finales fueron tomados sobre la base de datos que ellos crearon después de entrenar su modelo con el conjunto de datos PlantVillage. Obtuvo un accuracy de 99 % en

el tizón tardío y tizón temprano, mientras que en las hojas sanas tuvieron un accuracy de 100 %

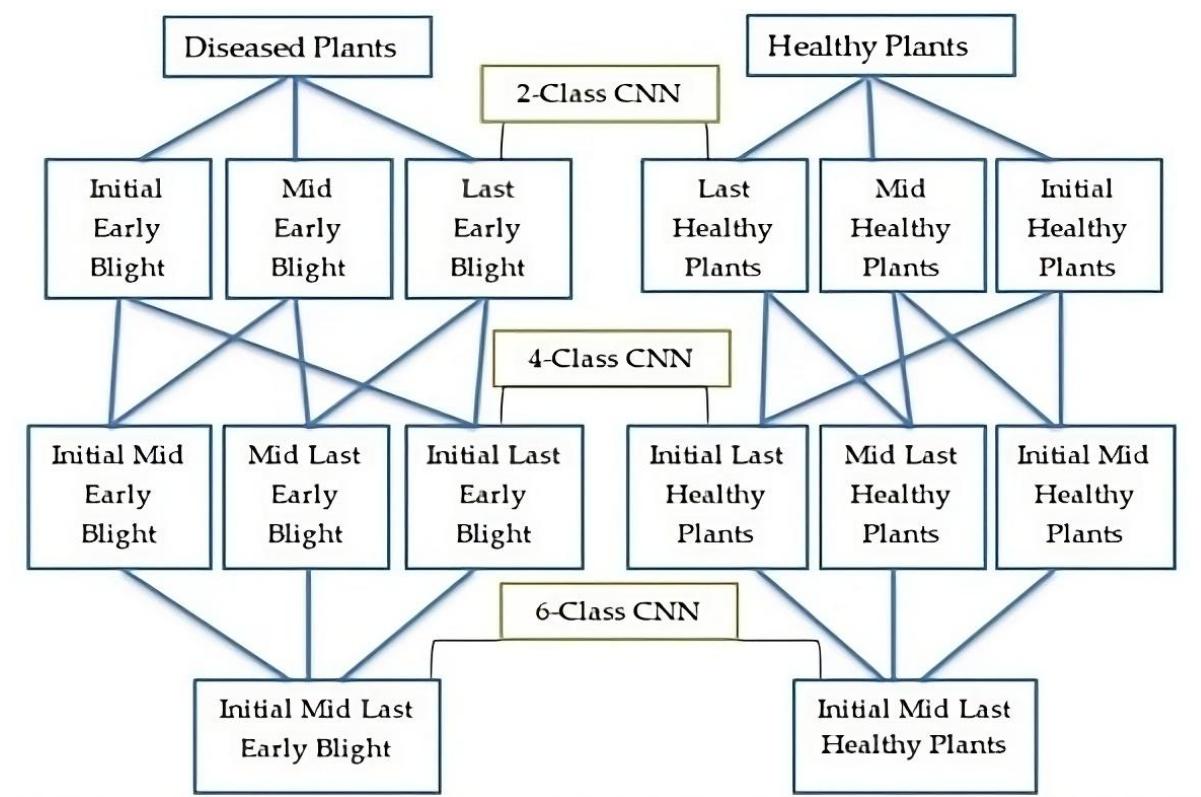


Figura 2.11: Arquitectura del modelo final (**anteceidente6**)

### 2.1.6. Potato Blight Classification Android Application using Deep Learning (**anteceidente7**)

**anteceidente7** realizó un artículo publicado en base de datos de ELSEVIER, siendo también parte de la revista Sustainable Chemistry and Pharmacy en el año 2022. Este fue titulado **anteceidente7** la cual traducida al español significa «Redes neuronales convolucionales profundas para la detección de enfermedades de la hoja del tomate basada en imágenes». El trabajo nos dice que el reconocimiento de enfermedades foliares en las plantas representa un riesgo significativo para la seguridad alimentaria, ya que puede reducir la producción agrícola y, por ende, la economía nacional. Es crucial identificar estas enfermedades en etapas tempranas para mejorar la calidad y cantidad de los productos agrícolas. Por lo tanto, se requiere un sistema automático de reconocimiento de enfermedades foliares que pueda identificar y clasificar estas enfermedades en etapas tempranas. En este contexto, se han utilizado modelos de redes neuronales convolucionales profundas (DCNN) para el análisis de imágenes de hojas, con el objetivo de mejorar la precisión y reducir el tiempo de respuesta en la identificación de enfermedades foliares en tomates. Se propone un sistema automático de identificación de

enfermedades foliares en tomates utilizando DCNN, con un conjunto de datos de 18160 imágenes de hojas de tomate. Este conjunto de datos se dividió en un 60 % para entrenamiento y un 40 % para pruebas, logrando una precisión del 98.40 % en el conjunto de pruebas con el modelo DCNN propuesto.

### **2.1.6.1. Planteamiento del Problema y objetivo**

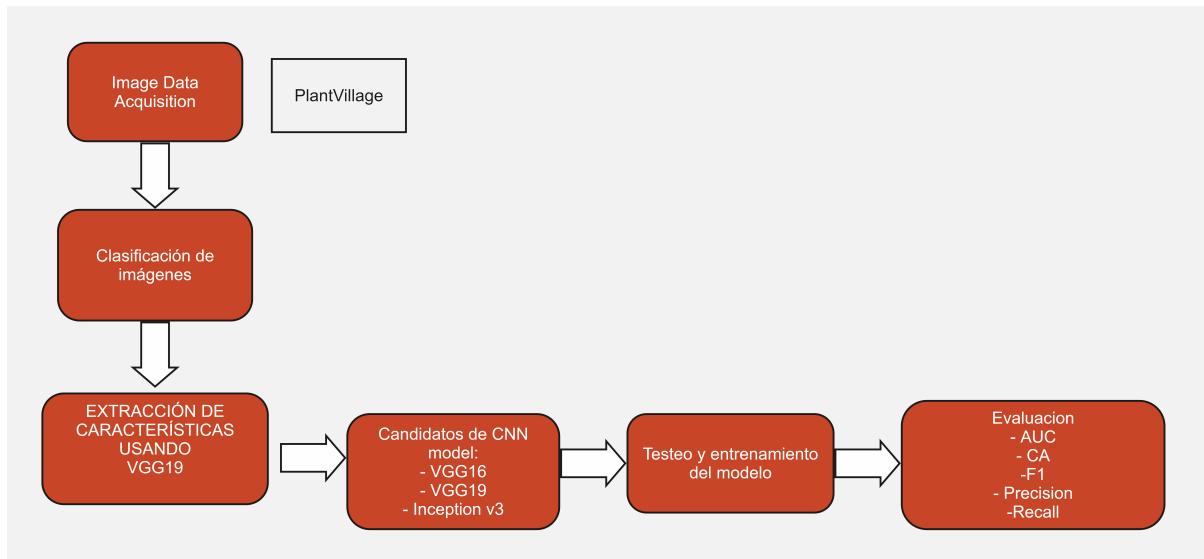
El artículo aborda principalmente que las enfermedades en las hojas de tomate causan pérdidas significativas en la producción, afectando tanto la calidad como la cantidad de los productos. Identificar y diagnosticar estas enfermedades de manera temprana es crucial, ya que pueden reducir drásticamente el crecimiento de los cultivos y, por lo tanto, la producción. Sin embargo, el diagnóstico manual de las enfermedades foliares puede llevar a una disminución en la producción debido a la gravedad de las enfermedades y a la variabilidad en los síntomas causada por factores ambientales como la temperatura, el viento y la humedad. Por lo tanto, existe una necesidad de desarrollar un sistema automático que pueda identificar y diagnosticar estas enfermedades en etapas tempranas, permitiendo a los agricultores tomar medidas preventivas adecuadas para proteger sus cultivos. El objetivo es desarrollar una herramienta automática que diagnostique las enfermedades de las hojas de tomate tempranamente para mejorar la producción agrícola. Se utilizará un enfoque basado en redes neuronales convolucionales profundas (DCNN) para clasificar 10 tipos de enfermedades en los cultivos de tomate, con el fin de identificar los síntomas de las hojas en etapas tempranas y mejorar la eficiencia y precisión del modelo mediante técnicas de ajuste de parámetros.

### **2.1.6.2. Fundamento Teórico usado por el Autor**

Los autores plantean utilizar como técnica principal una DCNN (Deep Convolutional Neural Networks) y compararla con técnicas como MLP (Multiplayer Layer Perceptron) y SVM (Support Vector Machine).

### **2.1.6.3. Metodología empleada por los autores**

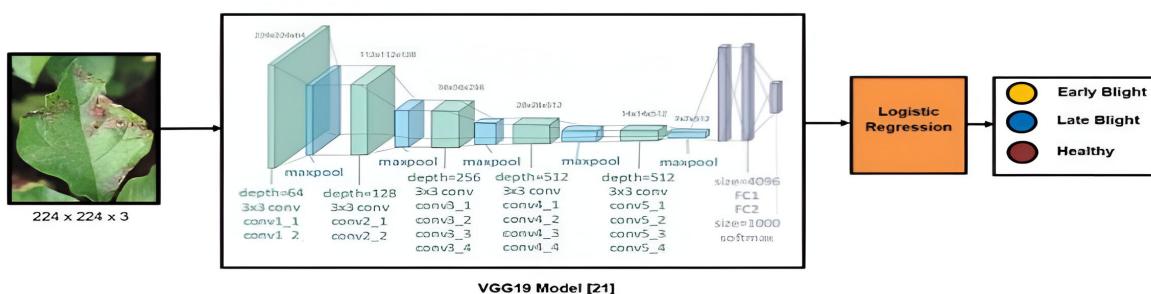
La metodología empleada por los autores, para la creación de su modelo consiste en los siguientes pasos:



**Figura 2.12:** Metodología (**antecedente7**)

#### 2.1.6.4. Resultados obtenidos

Para escoger su modelo consideraron VGG19 con la técnica de clasificación Logistic Regresion. Este alcanzó 97.8 % de accuracy sobre el testeo del dataset.



**Figura 2.13:** Arquitectura del modelo final (**antecedente7**)

#### 2.1.7. Investigation of Phytophthora Infestans Causing Potato Late Blight Disease: A Review (**antecedente4**)

**antecedente4** realizó un trabajo con el fin de ser publicado en la revista Biomedicine and Chemical Sciences. Este fue titulado **antecedente4** la cual traducida al español significa «Investigación de Phytophthora Infestans que causa el tizón tardío de la papa». La investigación sostiene Phytophthora infestans causa el tizón tardío de la papa, infectando raíces, tubércu-

los y brotes. La propagación se debe al cultivo de tubérculos infectados y restos de plantas en el campo. Las estructuras como micelio, zoosporas, oosporas y esporangios pueden causar infeción, y las oosporas pueden sobrevivir de 3 a 4 años en bajas temperaturas. *P. infestans* puede causar pérdidas de hasta el 100% en condiciones óptimas. Hay dos patrones de apareamiento, A1 y A2, y varios patrones genéticos que complican el control de la enfermedad. Las estrategias de control incluyen químicos, rotación de cultivos, agentes biológicos y plantas resistentes, siendo más efectivo combinar plantas resistentes y fungicidas. El artículo analiza los factores de propagación y desafíos del tizón tardío.

#### **2.1.7.1. Planteamiento del Problema y objetivo**

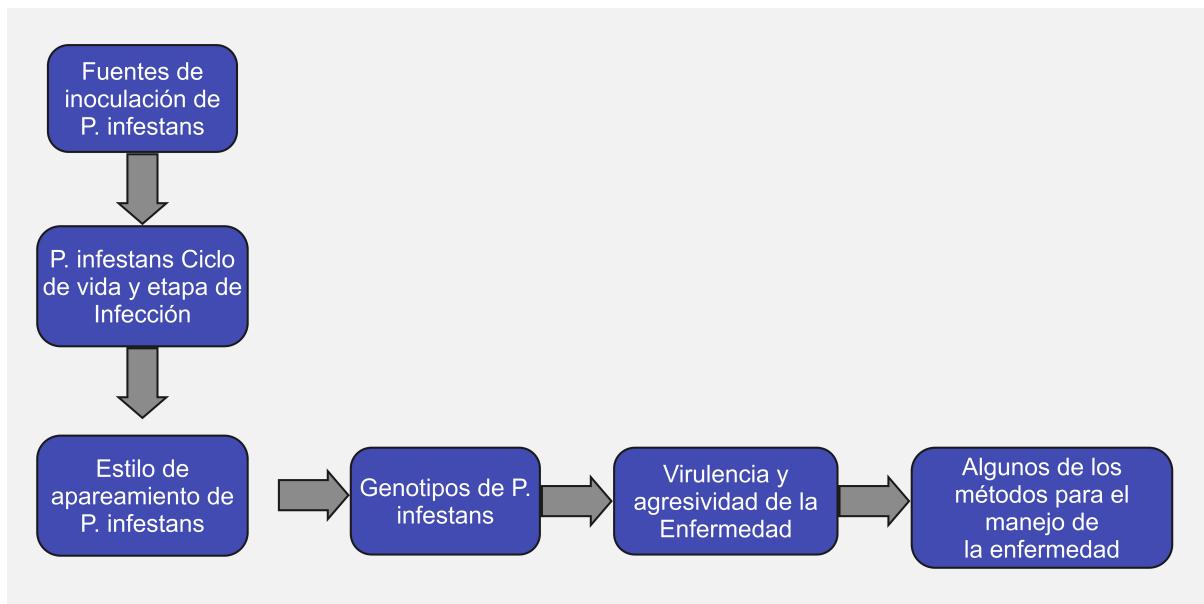
La investigación aborda que el hongo *Phytophthora* sp, con más de 60-80 especies, infecta diversas plantas, incluidas las papas y los tomates. *Phytophthora infestans*, en particular, causa estragos en estos cultivos, provocando pérdidas significativas de rendimiento y desencadenando eventos históricos como la hambruna irlandesa en la década de 1840. A pesar de los esfuerzos de control, la enfermedad del tizón tardío sigue siendo una amenaza global para la producción de papas, con pérdidas que pueden variar del 50 al 100% dependiendo de diversos factores ambientales y de gestión. El objetivo principal es investigar *Phytophthora infestans* y su impacto en la enfermedad del tizón tardío en las papas. Se busca comprender mejor los modos de infección, las estrategias de reproducción del patógeno y los factores que contribuyen a su agresividad. A través de esta investigación, se espera identificar mejores métodos de control y gestión de la enfermedad, incluyendo el uso de fungicidas, prácticas culturales y la resistencia de las plantas hospederas, para mitigar las pérdidas económicas y asegurar la seguridad alimentaria en las regiones afectadas.

#### **2.1.7.2. Fundamento Teórico usado por el Autor**

El autor desarrolla su investigación en base a múltiples investigaciones pasadas. Desde los orígenes del Tizón tardío, hasta su condición en el mundo actual.

#### **2.1.7.3. Metodología empleada por los autores**

La metodología empleada por el autor, para la creación de su chatbot consiste en los siguientes pasos:



**Figura 2.14:** Diagrama de la metodología(**antecedente4**)

#### 2.1.7.4. Resultados obtenidos

Los aislamientos de *P. infestans* tienen varias estructuras de infección que pueden infectar diferentes partes de la planta de papa y pueden sobrevivir durante un largo período. El hongo es capaz de reproducirse tanto sexual como asexualmente, y también presenta patrones de apareamiento A1 y A2 y diferentes genotipos. Todas estas características han llevado a la aparición de varios desafíos en el estudio de la virulencia y la agresividad. El segundo y más importante desafío incluye cómo elegir el mejor método para controlar la enfermedad (tizón tardío), ya que aparecen aislamientos que pueden resistir diferentes fungicidas, también pueden infectar plantas resistentes y muchas razones hacen que este desafío sea más importante.

## 2.2. Bases Teóricas

### 2.2.1. Inteligencia Artificial

Durante la conferencia de Dartmouth en 1956, el informático John McCarthy introdujo por primera vez el término *Inteligencia Artificial*.<sup>al</sup> mundo. McCarthy basó su concepto en los fundamentos teóricos publicados por Turing en 1950, donde se planteaba la posibilidad de que las máquinas pudieran pensar. En este evento, diversos investigadores y científicos expusieron los objetivos y la visión de la IA. Esta conferencia es ampliamente considerada como el punto

de partida de la inteligencia artificial según se sabe en la actualidad. (**teamredac2022**). Asimismo, hoy en día, no tenemos un concepto exacto acerca de la inteligencia artificial, debido a que es un tema complejo, por lo tanto, es posible hallar distintos conceptos acerca de ella. No obstante, la definición que se usará para términos de la investigación es que la inteligencia artificial es el poder de un ordenador de utilizar algoritmos, recibir datos, procesarlos y en base a esos pasos ser capaz de tomar decisiones similares a las de un ser humano. A diferencia de los humanos, la IA a través del procesamiento de conjuntos de información es capaz de crear máquinas y sistemas para resolver problemas que usualmente necesitan de inteligencia humana para resolverse. Muchos de los algoritmos de la IA se entrenan constituyéndose de datos para mejorar su rendimiento y optimizar las reglas establecidas, lo que se conoce como aprendizaje profundo (**rouhiainen2018inteligenciaricardo2021inteligenciacajahuanca2021inteligencia**). Por otro lado, hoy podemos encontrar diferentes tipos de IA, cada una con sus diferentes propósitos y características, de las más conocidas y aplicables en distintos campos académicos y profesionales, como la agricultura e ingeniería, son Deep learning, Vision Computer, este mismo contempla técnicas como Vision Transformer, Redes Neuronales Convolucionales, You Only Look One y técnicas para clasificación y regresión como Support Vector Machine.

### 2.2.2. Deep Learning

El Aprendizaje profundo, que particularmente se usa en los contextos donde la data es compleja y donde hay enormes cantidades de datos disponibles. Este subcampo de la inteligencia artificial se desarrolla mediante el uso de redes neuronales, las cuales se estructuran en niveles de procesamiento para identificar patrones y estructuras en conjuntos de datos extensos. Cada capa aprende un concepto de los datos sobre el que se basan las capas siguientes; cuanto más alto el nivel (capa), más abstractos son los conceptos aprendidos. El aprendizaje profundo no requiere un procesamiento previo de los datos y es capaz de extraer características de forma automática. Por poner una utilización sencilla, una red neuronal encargada de descifrar figuras aprendería a reconocer bordes simples en la primera capa y luego añadiría el reconocimiento de las figuras más complejas compuestas por esos bordes en las capas siguientes. No hay una regla fija sobre cuántas capas son necesarias para constituir una red neuronal profunda (**rusk2016deeprouhiainen2018inteligencia**). Hoy en día muchas de las compañías online y grandes consumidoras de tecnología usan Inteligencia profunda. Por citar a una, Facebook usa esta tecnología para analizar los textos de las conversaciones. Otras compañías como Google, Baidu, y Microsoft usan inteligencia profunda para búsqueda de imágenes, y también traslación de máquinas. Todos los teléfonos inteligentes poseen sistemas de inteligencia profunda corriendo en ellos. Ahora, inteligencia profunda es el estándar para tecnología para reconocimiento del habla, y también para la detección de rostros por cámaras digitales. La inteligencia profunda,

también es el centro de los autos que se manejan por sí mismos, donde es usual la localización y el mapeo, la percepción del entorno, planificación y dirección del movimiento, así como el seguimiento del estado del conductor. La inteligencia profunda está revolucionando la agricultura al proporcionar herramientas avanzadas para la clasificación y el análisis, lo que resulta en una mayor eficiencia, precisión y sostenibilidad en las prácticas agrícolas (**kelleher2019deep**).

### **2.2.3. Vision Computer**

Según **alonso2016vision**, la Visión por computadora también conocido como visión artificial es otra rama importante de la IA que desempeña la tarea de dotar al computador la función de captar y comprender una imagen con el objetivo de emular el proceso que realizan los humanos. A pesar de tener menos tiempo a comparación con las otras, desempeña una función básica, primordial y compleja del reconocimiento. Esta es capaz de aprender y reconocer formas para luego darles una clasificación correctamente. Posee funciones como el reconocimiento donde en la imagen se indaga un objeto singular o reconocer diferentes instancias de una categoría genérica donde se hace dicho reconocimiento de la instancia. Este reconocimiento está asignado para categorizar diferentes clases a los objetos, el instrumento que ejecuta este procedimiento se llama clasificador. Otro método es la representación de objetos, que se trata acerca de que los objetos sean identificados mediante segmentación de imágenes, pueden ser subdivididos en múltiples agrupaciones, desde el punto de agrupación, se provee de características comunes que tienen los objetos entre sí. El objeto medido según sus características es denominado patrón. Por último, tenemos al seguimiento de objetos en tiempo real, que consiste en que las técnicas o algoritmos de seguimiento estimen el movimiento de objetivo en el plano de la imagen mientras se da un contexto en movimiento, para eso el sistema coloca etiquetas fijas al objeto o los objetos a continuar durante continuidad de imágenes. La dificultad de esta técnica radica en los cambios inesperados en el movimiento, como la alteración en los aspectos de patrones, tal como de la escena, el propio objeto y las occlusiones entre objetos (**alonso2016vision**).

### **2.2.4. Vision Transformer: Explainability of Vision Transformers: A Comprehensive Review and New Perspectives (tecnica1)**

Los transformers han sido importantes en el procesamiento del lenguaje y, recientemente, se han destacado en la visión por computadora. Aunque su funcionamiento interno no se comprende completamente, la explicabilidad es crucial. Este estudio revisa métodos de explicabilidad para transformers visuales, propone una taxonomía y ofrece criterios de evaluación

y herramientas. También señala áreas no exploradas que podrían mejorar la explicabilidad y sugiere futuras investigaciones.

#### 2.2.4.1. Introducción

La Inteligencia Artificial (IA) ha experimentado avances notables en los últimos años, principalmente impulsada por el éxito de las Redes Neuronales Profundas (DNNs) en una amplia gama de aplicaciones, como el diagnóstico médico, las aplicaciones financieras, las evaluaciones de riesgos y la generación de imágenes y videos. Estos logros han sido significativos en términos de rendimiento y precisión en diversas tareas, sin embargo, la aplicación práctica de las DNNs sigue siendo limitada debido a su naturaleza opaca y la falta de transparencia en su toma de decisiones.

La opacidad de las DNNs plantea preocupaciones importantes en términos de confiabilidad y seguridad, ya que los usuarios y los responsables de la toma de decisiones pueden tener dificultades para comprender por qué un modelo ha llegado a una determinada conclusión o recomendación. Esto es particularmente problemático en áreas donde las decisiones basadas en IA pueden tener un impacto significativo en la vida de las personas, como la salud y la justicia. La falta de transparencia también puede ocultar sesgos y errores en los modelos, lo que socava aún más la confianza en su uso.

Para abordar estos desafíos, ha surgido el campo de la Inteligencia Artificial Explicable (XAI), cuyo objetivo es mejorar la comprensión y la transparencia de los modelos de IA. La XAI busca proporcionar explicaciones claras y comprensibles sobre cómo se toman las decisiones por parte de los modelos de IA, permitiendo a los usuarios entender y confiar en sus resultados. Al comprender cómo funciona un modelo y por qué toma ciertas decisiones, los usuarios pueden evaluar mejor su fiabilidad y corregir posibles sesgos o errores.

En este contexto, los transformers, modelos basados en atención, han surgido como una alternativa poderosa a las arquitecturas de redes neuronales convolucionales (CNNs) tradicionales en áreas como el Procesamiento del Lenguaje Natural (NLP) y la Visión por Computadora (CV). Los transformers han demostrado ser altamente efectivos para capturar relaciones a largo plazo en datos secuenciales, lo que los hace adecuados para tareas que requieren un procesamiento de contexto complejo.

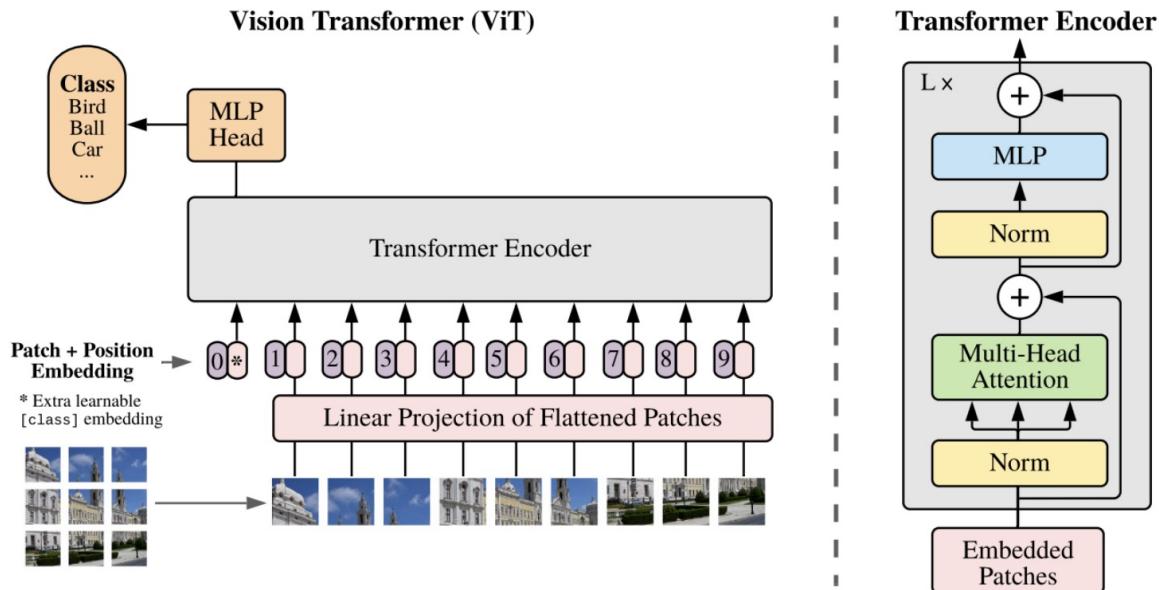
En particular, los Vision Transformers (ViT) aplican la arquitectura de transformers a la tarea de visión por computadora, lo que ha llevado a avances significativos en tareas como el reconocimiento de imágenes, la detección de objetos y la segmentación de imágenes. Los ViT han demostrado resultados comparables e incluso superiores a los obtenidos con CNNs en

algunas aplicaciones.

Sin embargo, a pesar de su éxito, la comprensión y la explicabilidad de los transformers, especialmente en el contexto de la visión por computadora, siguen siendo áreas de investigación activa. Se necesitan métodos y técnicas robustas para explicar las decisiones tomadas por estos modelos, así como herramientas y marcos para evaluar y comparar sus explicaciones. Al mejorar la explicabilidad de los transformers, podemos fortalecer la confianza en su uso y abrir nuevas oportunidades para aplicaciones prácticas en una variedad de campos.

#### 2.2.4.2. Arquitectura de Vision Transformer

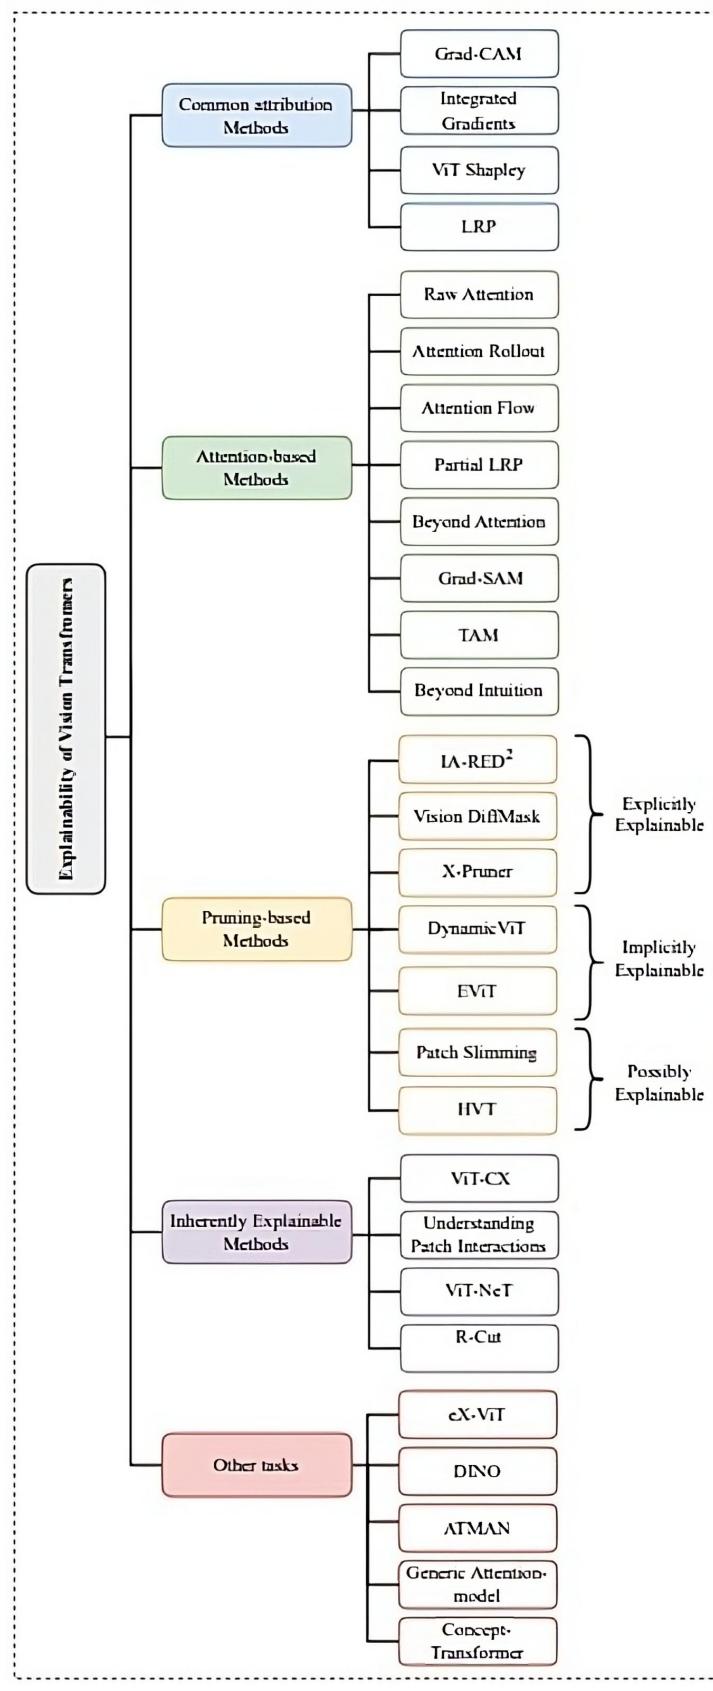
Los Vision Transformers (ViTs) aprovechan los avances de los transformers en NLP para aplicaciones visuales. Utilizan bloques de transformers que permiten integrar información global en toda la imagen mediante auto-atención. Las imágenes se representan como secuencias de tokens, con una capa de incrustación de parches para dividirlas en parches. Estos parches se aplanan y se tratan como tokens, luego se transforman en vectores de características. Para la clasificación, se agrega un token de clasificación. La red ViT también incluye otros componentes como una activación GELU, normalización de capa y conexión residual. Se puede encontrar una ilustración de la arquitectura ViT en la Figura 7.



**Figura 2.15:** Arquitectura de Vision Transformer (**technical1**)

### 2.2.4.3. Explicacion y métodos para Visual Transformer

Tras los trabajos innovadores presentados basados en transformers visuales para diversos dominios de visión por computadora, han surgido múltiples enfoques para mejorar la explicabilidad de estas redes. Sin embargo, se necesita una encuesta exhaustiva para comprender mejor estos métodos e identificar áreas de mejora. Con un enfoque en la tarea de clasificación, esta sección presenta una visión general de las técnicas de explicabilidad existentes para transformers visuales. Para proporcionar una visión clara, categorizamos y resumimos estos métodos en cinco grupos distintos según sus procedimientos de trabajo, motivaciones y características estructurales, como se ilustra en la Figura 8.



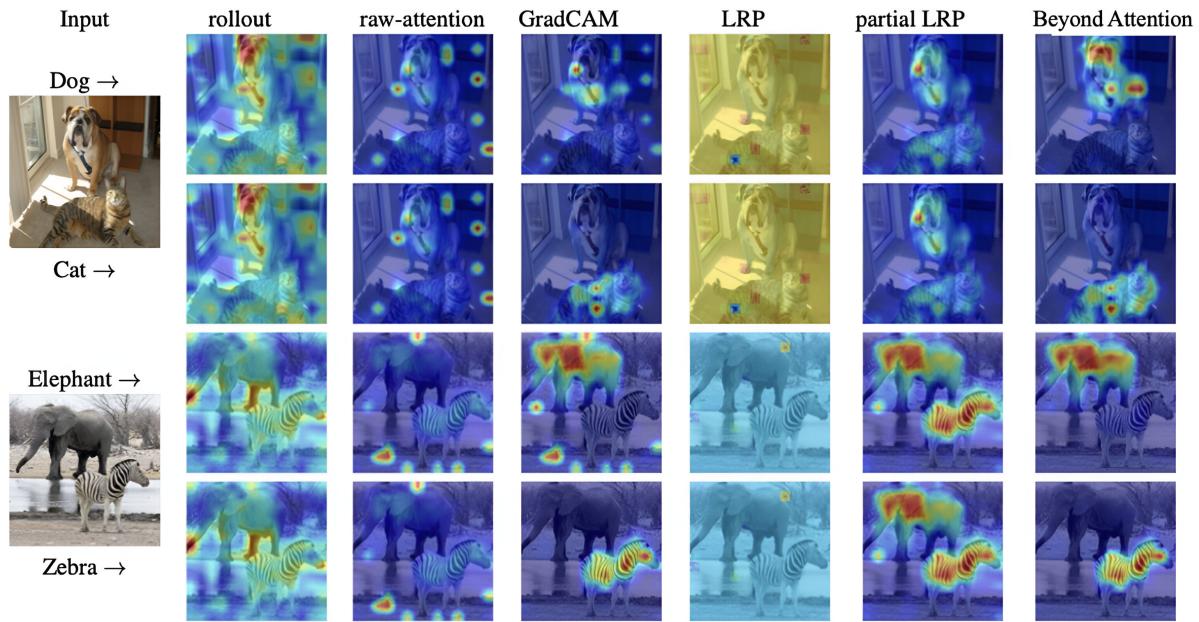
**Figura 2.16:** Taxonomía de los métodos de explicabilidad para Transformadores de visión (técnica1)

#### 2.2.4.4. Métodos basados en atención

Los métodos basados en atención aprovechan el mecanismo de atención de los modelos para identificar y priorizar las partes más relevantes de una secuencia de entrada. Muchos enfoques existentes se centran en utilizar los pesos de atención o el conocimiento codificado en ellos para explicar el comportamiento del modelo. En aplicaciones basadas en visión, la visualización de los pesos de atención puede ser útil para identificar patrones de atención, aunque puede volverse menos confiable a medida que la red crece más profunda y más compleja. Para superar estos desafíos, se han introducido dos métodos: "Attention Rollout" y "Attention Flow", que cuantifican el flujo de información y aproximan la atención a los tokens de entrada de manera más holística. Estos métodos tienen sus limitaciones, por lo que se han desarrollado enfoques adicionales, como "GradSAM" y "Transition Attention Maps" (TAM), que aplican funciones como gradientes a los pesos de atención para mejorar la explicación de las predicciones del modelo. Además, el marco "Beyond Intuition" propone una aproximación novedosa para aproximarse a las contribuciones de los tokens, operando en dos etapas: percepción de atención y retroalimentación de razonamiento.

| Methods           | Attention-based | Class-specific | Multi-modality | Backbone      | Date |
|-------------------|-----------------|----------------|----------------|---------------|------|
| Raw Attention     | Yes             | No             | No             | VIT,DEIT      | 2017 |
| Attention Rollout | Yes             | No             | No             | VIT,DEIT      | 2020 |
| Attention Flow    | Yes             | No             | No             | VIT,DEIT      | 2020 |
| Partial LRP       | Yes             | No             | No             | VIT           | 2019 |
| Grad-SAM          | Yes             | Yes            | No             | VIT           | 2021 |
| Beyond Attention  | Yes             | Yes            | Yes            | VIT           | 2021 |
| TAM               | Yes             | Yes            | No             | VIT,DEIT      | 2021 |
| Beyond Intuition  | Yes             | Yes            | Yes            | BERT,VIT,CLIP | 2023 |

**Figura 2.17:** Comparación de los métodos basados en atención desde diferentes perspectivas (técnica1)



**Figura 2.18:** Visualizaciones específicas de clase de varios métodos basados en la atención, para cada imagen se pueden ver resultados de dos clases diferentes(**técnica1**)

#### 2.2.4.5. Métodos basados en la poda

Los métodos basados en poda son una poderosa herramienta utilizada para optimizar la eficiencia y complejidad de los transformers. Estos métodos intentan eliminar elementos redundantes o poco informativos como tokens, parches, bloques o cabezas de atención de las redes. Algunos de estos métodos están explícitamente desarrollados con fines de explicabilidad, mientras que otros se centran principalmente en mejorar la eficiencia y no tienen como objetivo específico la explicabilidad. Sin embargo, estudios indican que las técnicas del segundo grupo también pueden impactar positivamente la explicabilidad del modelo. Se pueden categorizar los métodos de poda basados en ViT en tres grupos: métodos explícitamente explicables, implícitamente explicables y posiblemente explicables.

Entre los métodos de poda explícitamente explicables, hay varios enfoques notables que buscan proporcionar modelos menos complejos y más interpretables. Por ejemplo, el método IA-RED2 busca encontrar el equilibrio perfecto entre eficiencia e interpretabilidad al eliminar dinámicamente los parches menos informativos, lo que resulta en una velocidad significativamente mayor con una pérdida mínima de precisión. Otro método, X-Pruner, está diseñado específicamente para podar unidades menos significativas, logrando importantes ahorros computacionales sin perder precisión.

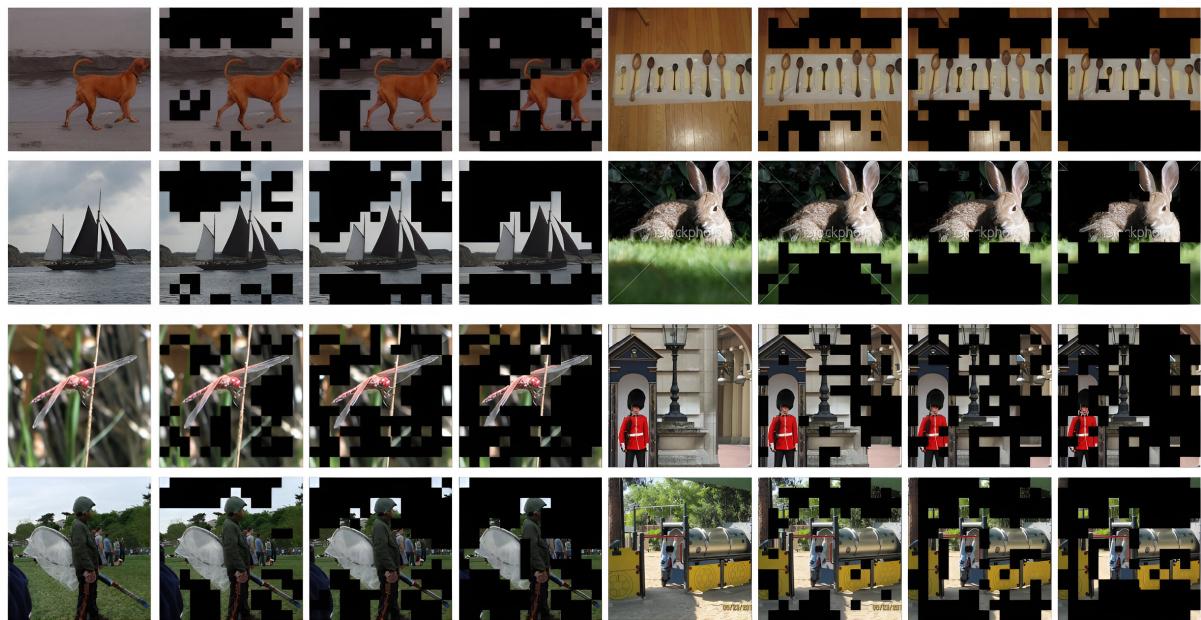
Por otro lado, los métodos de poda implícitamente explicables, como el marco Dy-

namicViT, están diseñados principalmente para mejorar la eficiencia de la red, pero también pueden mejorar la explicabilidad al localizar las partes críticas de la imagen que contribuyen más a la clasificación. EViT es otro enfoque innovador que reorganiza los tokens de una imagen basándose en el concepto de atención, manteniendo los tokens más relevantes mientras fusiona los menos atentos en un solo token, lo que reduce los costos computacionales sin comprometer la precisión del modelo. Estos métodos mejoran la interpretabilidad y ofrecen una comprensión más clara de las decisiones del modelo.

| Pruning Method      | GFLOPs ↓ (%) | TOP-1 Accuracy ↓ (%) | Throughput ↑ (%) |
|---------------------|--------------|----------------------|------------------|
| IA-RED <sup>2</sup> | —            | 0.7                  | 46               |
| X-Pruner            | 47.9         | 1.09                 | —                |
| DynamicViT          | 37           | 0.5                  | 54               |
| EViT                | 35           | 0.3                  | 50               |
| Patch Slimming      | 47.8         | 0.3                  | 43               |
| HVT                 | 47.8         | 1.8                  | —                |

**Figura 2.19:** Comparación de diferentes métodos basados en la poda aplicados a DeiT-S en el conjunto de datos ImageNet(**técnica1**)

Los métodos posiblemente explicables son enfoques adicionales de poda que, aunque inicialmente no se diseñaron para mejorar la interpretabilidad de ViT, podrían ofrecer un potencial para investigar su impacto en la explicabilidad de los modelos. Por ejemplo, Patch Slimming es un algoritmo novedoso que acelera ViTs al dirigirse a los parches redundantes en las imágenes de entrada, lo que potencialmente destaca características visuales importantes y mejora la interpretabilidad. Otro enfoque, Hierarchical Visual Transformer (HVT), mejora la escalabilidad y el rendimiento de ViTs al reducir gradualmente la longitud de la secuencia a medida que aumenta la profundidad del modelo. Aunque estos métodos se han evaluado principalmente en términos de eficiencia, existe una brecha significativa en la literatura en cuanto a la evaluación de su explicabilidad. En contraste, los métodos inherentemente explicables, como ViT-CX, se centran en desarrollar modelos que puedan explicarse a sí mismos, utilizando herramientas interpretables como mapas de saliencia para proporcionar explicaciones más significativas.



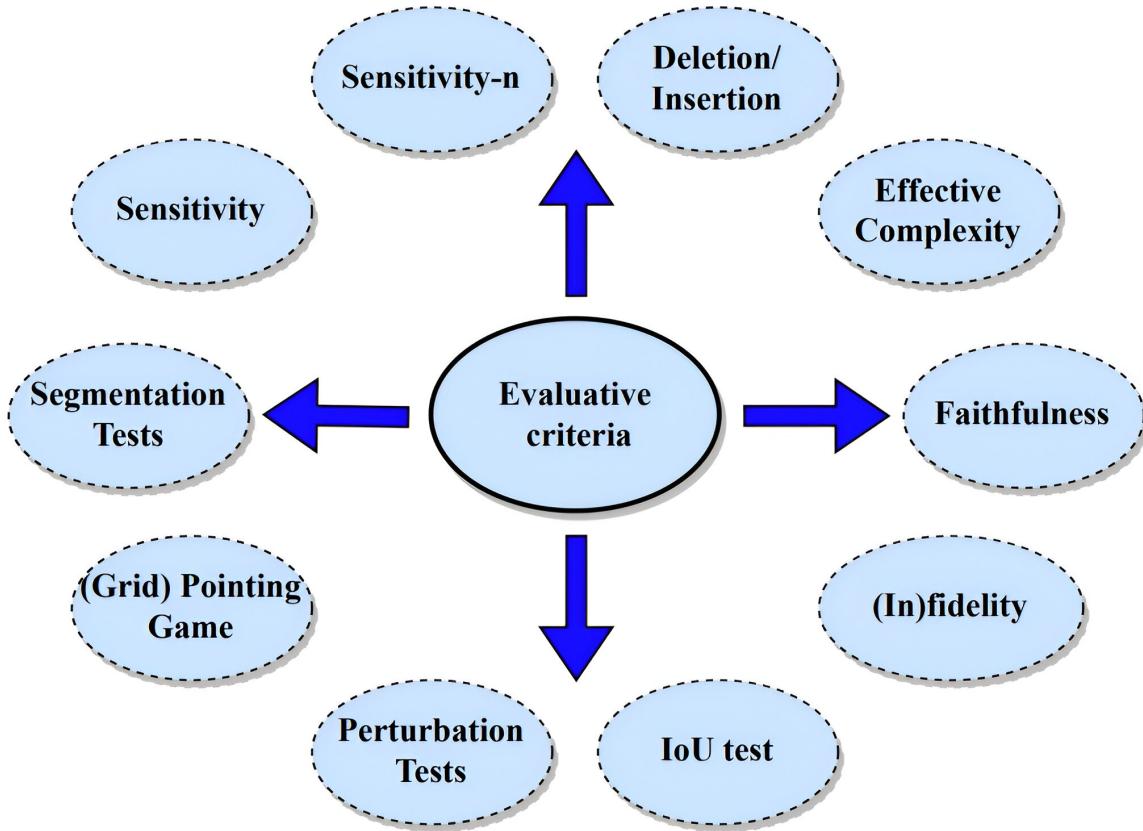
**Figura 2.20:** Visualización de tokens desatentos en EViT-DeiT-S con 12 capas; Se puede ver que las fichas de falta de atención se fusionan gradualmente (como se representa mediante áreas enmascaradas) o se eliminan, mientras que las fichas más informativas se conservan. Esto permite a los ViT centrarse en tokens específicos de clase en imágenes, lo que conduce a una mejor interpretabilidad(**técnica1**)

#### 2.2.4.6. Evaluación de explicación

En secciones anteriores, presentamos varias técnicas de explicación desarrolladas específicamente para aplicaciones basadas en ViT. Sin embargo, evaluar qué tan bien estas técnicas representan el proceso de razonamiento de un modelo presenta diferentes desafíos. Para abordar esta preocupación, la literatura sugiere una serie de criterios evaluativos, que ayudan a seleccionar y diseñar la técnica de explicabilidad más apropiada. A continuación, se resumen estos criterios:

- **Deletion and Insertion:** Se utilizan para evaluar la fidelidad de un mapa de saliencia al modelo objetivo. Calculan cómo el mapa de saliencia identifica los píxeles más influyentes para la predicción del modelo.
- **Effective Complexity:** Evalúa el número de atribuciones que superan un umbral, indicando la importancia o insignificancia de las características correspondientes.
- **Faithfulness:** Método para evaluar la calidad de las atribuciones de características sin intervención humana, midiendo cuán precisamente las atribuciones de características se alinean o correlacionan con las predicciones del modelo.

- **(In)fidelity:** Se utiliza para evaluar qué tan bien una explicación captura los cambios en las predicciones de un modelo cuando la entrada sufre perturbaciones significativas.
- **Intersection over Union (IoU) test:** Métrica estándar para evaluar el rendimiento de los detectores y seguidores de objetos, que también se ha utilizado para evaluar métodos de explicabilidad midiendo la superposición entre los mapas de explicabilidad predichos y las cajas delimitadoras de la verdad terrenal de los objetos de interés.
- **Perturbation Tests:** Funcionan al enmascarar gradualmente tokens de entrada basándose en las explicaciones proporcionadas por el método de explicabilidad dado.
- **Pointing Game:** Método para evaluar los mapas de saliencia de la explicación en comparación con las cajas delimitadoras anotadas por humanos.
- **Segmentation Tests:** Consideran cada visualización como una segmentación suave de la imagen y las comparan con la verdad terrenal proporcionada en el conjunto de datos.
- **Sensitivity:** Evalúa cómo varían las explicaciones con pequeñas perturbaciones en la entrada.
- **Sensitivity-n:** Propuesto para probar valores de atribución específicos en lugar de considerar solo las clasificaciones de importancia.



**Figura 2.21:** Diferentes criterios para evaluar los métodos de explicabilidad en aplicaciones basadas en la visión(**técnica1**)

#### 2.2.4.7. Conclusión

En resumen, este trabajo ofrece una visión completa de las técnicas de explicabilidad propuestas para los transformers visuales. Hemos proporcionado una taxonomía de los métodos basada en sus motivaciones, estructuras y escenarios de aplicación, categorizándolos en cinco grupos. Además, detallamos los criterios de evaluación de la explicabilidad, así como las herramientas y marcos de trabajo utilizados. Por último, discutimos varios problemas esenciales pero poco explorados para mejorar la explicabilidad de los transformers visuales y sugerimos direcciones de investigación potenciales para futuras inversiones. Esperamos que este artículo de revisión ayude a los lectores a comprender mejor los mecanismos internos de los transformers visuales, así como a resaltar problemas abiertos para trabajos futuros.

### **2.2.5. Redes neuronales convolucionales**

### **2.2.6. You Only Look One (YOLO)**

### **2.2.7. Support Vector Machine**

## **2.3. Marco Conceptual**

Para de

# **Capítulo 3**

## **METODOLOGÍA DE LA INVESTIGACIÓN**

### **3.1. Diseño de la investigación**

En esta sección del documento se explicará cual es el diseño, el tipo y el enfoque del trabajo de investigación, así como también la población y la muestra.

#### **3.1.1. Diseño no experimental**

El diseño es no experimental transversal, ya que las variables no serán manipuladas y serán analizadas tal como se encuentran. Es decir, tanto los datos visuales de las hojas de papa peruana afectadas por la enfermedad 'Rancha' (*Phytophthora infestans*) como las técnicas de visión computacional serán utilizados sin modificar ningún aspecto de las condiciones naturales. El objetivo es aplicar técnicas de visión computacional para clasificar tempranamente la presencia de la enfermedad en las hojas de papa. La recolección de datos se llevará a cabo en un periodo de tiempo específico, sin intervenir en el desarrollo natural de la enfermedad en las plantas

#### **3.1.2. Tipo explicativo**

El alcance de esta investigación es explicativo, ya que se enfoca en construir un modelo de visión computacional para la detección temprana de la enfermedad 'Rancha' (*Phytophthora infestans*) a partir de imágenes de hojas de papa. Esto busca entender cómo identificar si una

hoja de papa está afectada por el tizón tardío, estableciendo así una relación de causa y efecto. En otras palabras, al identificar un patrón específico en las hojas de papa con Ranchas, se podrá determinar si están afectadas por la patología.

### 3.1.3. Enfoque cuantitativo

El enfoque de esta investigación es cuantitativo, dado que se emplearán técnicas de visión computacional, las cuales implican procesar datos de imagen en valores numéricos (vectores de características). Posteriormente, se usarán técnicas estadísticas para analizar estos datos y determinar la presencia de la enfermedad 'Ranchas' (*Phytophthora infestans*) en las hojas de papa peruana.

## 3.2. Población

La población fueron todas las imágenes de hojas de papa infestadas con Tizón tardío y hojas de papa sanas.

## 3.3. Muestra

La muestra se extrajo un conjunto de imágenes de los dataset Plant Diseases Training Dataset, el cual es una recopilación de otras agrupaciones de datos como PlantVillage, Potato Leaf Disease, Cassava Leaf Disease Dataset, etc. Se cuenta con 1777 imágenes de hojas de papa etiquetadas como sanas y 2020 como infestadas con Tizón tardío. Adicionalmente, cabe mencionar, que para el propósito de esta investigación se utilizará 80 % del conjunto de imágenes total para Training y 20 % para el Testing de los modelos correspondientes. La Figura 3.1 y el Cuadro 3.1

## 3.4. Operacionalización de Variables

Nisi porta lorem mollis aliquam ut porttitor leo. Aenean pharetra magna ac placerat vestibulum. Est placerat in egestas erat imperdible sed euismod. Velit euismod in pellentesque massa placerat. Enim praesent elementum facilisis leo vel fringilla. Ante in nibh mauris cursus mattis molestie a iaculis. Erat pellentesque adipiscing commodo elit at imperdible dui accumsan



**Figura 3.1:** Hoja de papa infestada con Tizón tardío

sit. Porttitor lacus luctus accumsan tortor posuere ac ut. Tortor at auctor urna nunc id. A iaculis at erat pellentesque adipiscing commodo elit.

### 3.5. Instrumentos de medida

Nisi porta lorem mollis aliquam ut porttitor leo. Aenean pharetra magna ac placerat

- muscle and fat cells remove glucose from the blood,
- cells breakdown glucose via glycolysis and the citrate cycle, storing its energy in the form of ATP,
- liver and muscle store glucose as glycogen as a short-term energy reserve,
- adipose tissue stores glucose as fat for long-term energy reserve, and

- cells use glucose for protein synthesis.

## 3.6. Técnicas de recolección de datos

Nisi porta lorem mollis aliquam ut porttitor leo. Aenean pharetra magna ac placerat vestibulum. Est placerat in egestas erat imperdiet sed euismod. Velit euismod in pellentesque massa placerat. Enim praesent elementum facilisis leo vel fringilla. Ante in nibh mauris cursus mattis molestie a iaculis. Erat pellentesque adipiscing commodo elit at imperdiet dui accumsan sit. Porttitor lacus luctus accumsan tortor posuere ac ut. Tortor at auctor urna nunc id. A iaculis at erat pellentesque adipiscing commodo elit.

$\text{\LaTeX}$  is great at typesetting mathematics. Let  $X_1, X_2, \dots, X_n$  be a sequence of independent and identically distributed random variables with

$$S_n = \frac{X_1 + X_2 + \dots + X_n}{n} = \frac{1}{n} \sum_i^n X_i \quad (\text{Ecuación 3.1})$$

La Ecuación [Ecuación 3.1](#) denote their mean. Then as  $n$  approaches infinity, the random variables

$$\sqrt{n}(S_n - \mu)$$

converge in distribution to a normal  $\mathcal{N}(0, \sigma^2)$ .

## 3.7. Técnicas para el procesamiento y análisis de la información

Nisi porta lorem mollis aliquam ut porttitor leo. Aenean pharetra magna ac placerat vestibulum. Est placerat in egestas erat imperdiet sed euismod. Velit euismod in pellentesque massa placerat. Enim praesent elementum facilisis leo vel fringilla. Ante in nibh mauris cursus mattis molestie a iaculis. Erat pellentesque adipiscing commodo elit at imperdiet dui accumsan sit. Porttitor lacus luctus accumsan tortor posuere ac ut. Tortor at auctor urna nunc id. A iaculis at erat pellentesque adipiscing commodo elit.

You can make lists with automatic numbering ...

1. Like this,
2. and like this.

... or bullet points ...

- Like this,
- and like this.

### 3.8. Cronograma de actividades y presupuesto

Nisi porta lorem mollis aliquam ut porttitor leo. Aenean pharetra magna ac placerat vestibulum. Est placerat in egestas erat imperdiet sed euismod. Velit euismod in pellentesque massa placerat. Enim praesent elementum facilisis leo vel fringilla. Ante in nibh mauris cursus mattis molestie a iaculis. Erat pellentesque adipiscing commodo elit at imperdiet dui accumsan sit. Porttitor lacus luctus accumsan tortor posuere ac ut. Tortor at auctor urna nunc id. A iaculis at erat pellentesque adipiscing commodo elit.

| Item    | Quantity |
|---------|----------|
| Widgets | 42       |
| Gadgets | 13       |

**Tabla 3.1:** An example table.

## **Anexos A**

### **Anexo I: Matriz de Consistencia**

| PROBLEMAS  | OBJETIVOS   | HIPÓTESIS  |
|--|---|--|
| Problema General   | Objetivo General  | Hipótesis General  |
| ¿Es posible desarrollar un sistema de visión computacional que permita la clasificación temprana de la rancha ( <i>Phytophthora infestans</i> ) en hojas de papa peruana con alta precisión?   | Desarrollar un sistema de visión computacional basado en técnicas de aprendizaje profundo para la clasificación temprana de la rancha ( <i>Phytophthora infestans</i> ) en hojas de papa peruana. | Se sostiene que mediante el desarrollo de un sistema de clasificación automática de las lesiones de Rancha” <i>Phytophthora infestans</i> en las hojas de papa peruana, se puede lograr un método de detección la Rancha en las hojas de papa peruana.                   |
| Problemas Específicos  | Objetivos Específicos   | Hipótesis Específicas  |
| ¿Cómo podemos desarrollar un sistema de detección automática de Rancha” <i>Phytophthora infestans</i> en las hojas de papa peruana que sea preciso, eficiente y robusto a la variabilidad de las lesiones y las condiciones ambientales? | Desarrollar un sistema de detección automática de Rancha” <i>Phytophthora infestans</i> que alcance una precisión alta en la detección de lesiones en las hojas de papa.                          | La implementación de técnicas de aprendizaje automático y detección de imágenes permitirá desarrollar un sistema de detección automática de Rancha” <i>Phytophthora infestans</i> con alta precisión.  |
| ¿Cómo obtener un conjunto de datos representativo y diverso de imágenes de hojas de papa con Rancha y sin ella?  | Recolectar un conjunto de datos amplio y diverso de imágenes de hojas de papa que cubra una variedad de condiciones y escenarios relevantes para la detección de la Rancha.                       | La recopilación de un conjunto de datos representativo y diverso proporcionará una base sólida para el entrenamiento y la validación de los algoritmos de visión computacional, lo que mejorará su capacidad para detectar con precisión la Rancha en las hojas de papa. |
| ¿Cuáles son las técnicas de visión computacional más apropiadas para la detección temprana de Rancha. <sup>en</sup> hojas de papa peruano?   | Identificar las técnicas de visión computacional más adecuadas para la detección temprana de Rancha. <sup>en</sup> hojas de papa peruana.   | Se sostiene que al investigar específicamente técnicas de visión computacional, se logrará una mejora significativa en la detección temprana de Rancha. <sup>en</sup> hojas de papa peruano.   |
| ¿Cuáles son las técnicas de preprocessamiento de imágenes más apropiadas para la detección temprana de Rancha. <sup>en</sup> hojas de papa peruano??   | Identificar las técnicas de preprocessamiento de imágenes más adecuadas para la detección temprana de Rancha. <sup>en</sup> hojas de papa peruana.  | Se sostiene que al investigar específicamente técnicas de preprocessamiento de imágenes, se logrará una mejora significativa en la detección temprana de -ancha. <sup>en</sup> hojas de papa peruano.  |

**Tabla A.1:** Matriz de consistencia. Fuente: Elaboración propia

## **Anexos B**

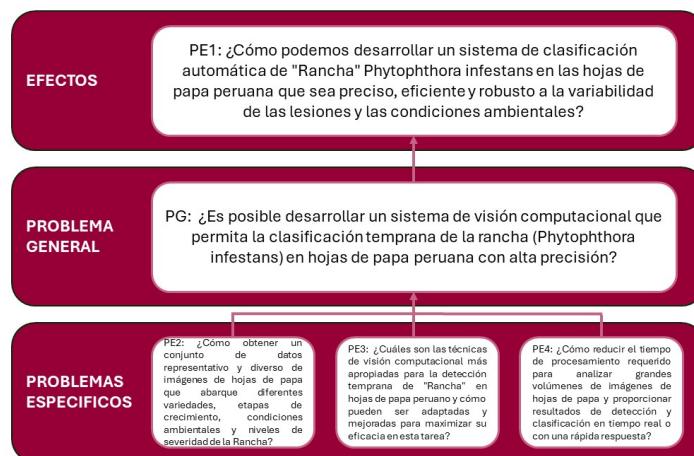
### **Anexo II: Resumen de Papers investigados**

| Tipo      | Nº | Título  | Autor   | Año  | País       | Fuente   |
|-----------|----|---|---|------|------------|--|
| Problema  | 1  | Design and Development of AI-Powered Healthcare WhatsApp Chatbot  | Prakasam S and N. Balakrishnan and Kirthickram T R and Ajith Jerom B and Deepak S | 2023 | India      | IEEE   |
|           | 2  | Artificial Intelligence Powered Chatbot for Mental Healthcare based on Sentiment Analysis   | Ansh Mehta and Sukhada Virkar and Jay Khatri and Rhutuja Thakur and Ashwini Dalvi | 2022 | India      | IEEE   |
| Propuesta | 3  | Use of chatbots for customer service in MSMEs   | Jorge Cordero, Luis Barba-Guaman and Franco Guamán                                | 2022 | Ecuador    | Universidad Técnica Particular de Loja   |
|           | 4  | Chatbot: una propuesta viable para la atención al cliente en el centro de soporte de la UCI   | Rosbel Caballero Ramírez  | 2021 | Cuba       | Revista Cubana de Ciencias Informática   |
| Técnica   | 5  | The Science of Detecting LLM-Generated Text   | Ruixiang Tang and Yu-Neng Chuang and Xia Hu                                       | 2024 | China      | Communications of the ACM  |
|           | 6  | Review on Implementation Techniques of Chatbot  | Nithuna S and Laseena C.A   | 2020 | India      | International Conference on Communication and Signal Processing                          |
|           | 7  | AI-Based Chatbot  | Aarush Saxena   | 2024 | India      | International Journal for Research in Applied Science & Engineering Technology (IJRASET) |
|           | 8  | Revisiting university students' intention to accept AI-Powered chatbot with an integration between TAM and SCT: a south Asian perspective | Md. Rabiul Awal and Md. Enamul Haque  | 2024 | Bangladesh | ResearchGate - Journal of Applied Research in Higher Education                           |

**Tabla B.1:** Cuadro Resumen de Papers investigados. Fuente: Elaboración propia

## Anexos C

### Anexo III: Árbol del problema

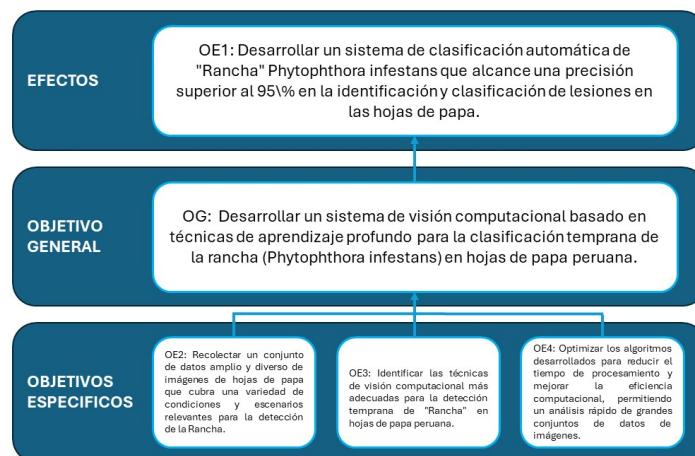


**Figura C.1:** Arbol de problemas

Fuente: Creación Propia

## Anexos D

### Anexo III: Árbol de objetivo



**Figura D.1:** Arbol de problemas

Fuente: Creación Propia